



教学内容

智能信息网络

- | | | |
|----|--------------------|-------|
| 1 | 智能信息网络概述 | |
| 2 | 高速宽带信息网络技术 | (基础篇) |
| 3 | 信息网络性能分析技术 | (基础篇) |
| 4 | 网络数据的智能处理技术 | (基础篇) |
| 5 | 网络中常用的智能算法 | (基础篇) |
| 6 | 网络智能规划 | (应用篇) |
| 7 | 网络智能部署 | (应用篇) |
| 8 | 网络智能运维 | (应用篇) |
| 9 | 网络智能优化 | (应用篇) |
| 10 | 智能信息网络发展前景 | |

2

第 4 章

网络数据的智能处理技术



3



4

第4章 主要参考资料

1. 武志学. 大数据导论- 思维、技术与应用[M], 人民邮电出版社, 2019
2. 林阳光. 网络流量数据可视化建设和分析方法[J]. 数字通信世界, 2017
3. 吴乐南. 数据压缩[M], 电子工业出版社, 2012.
4. 4. 晏燕,李立, 彭清斌. 多媒体通信——原理、技术及应用[M], 清华大学出版社, 2019.
5. 4. 鄢航程. 数据压缩的实用性及必要性. <http://www.doc88.com/p-7975215224355.html>
6. Apriori算法详解: <https://zhuanlan.zhihu.com/p/341882260>
7. 机器学习: 降维技术完整指南,
<https://baijiahao.baidu.com/s?id=1664419210560925668&wfr=spider&for=pc>

5

第4章 内容提要

4

4.1 大数据的基本概念与特征

4.2 数据获取技术

4.3 智能处理技术

4.4 数据可视化技术

4.5 大数据应用示例

问题:

1. 如何分析和处理数据?
2. 数据能给通信网络带来什么?

6

第4章 学习目标与教学思路

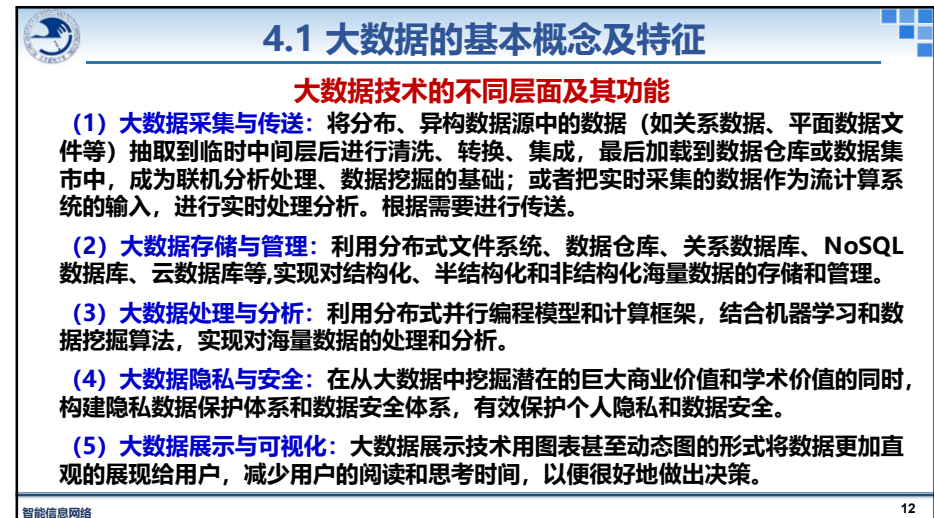

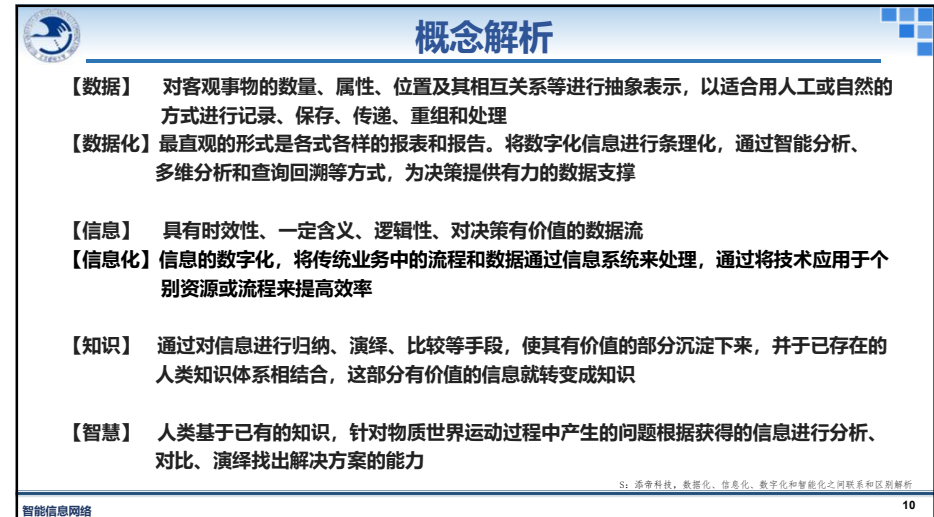
- 掌握大数据基本处理方法
- 了解大数据的可视化技术
- 初步学习和掌握大数据的分析和应用

3要点: 基本概念, 基本结构, 基本功能

7

4.1 大数据的基本概念及特征

8



4.1 大数据的基本概念及特征

车联网系统数据采集传送

◆ 车载终端
采集车辆实时运行数据，实现对车辆所有工作信息和静、动态信息的采集、存储并发送。

◆ 云计算处理平台
处理车辆信息，对数据进行“过滤清洗”；

◆ 数据分析平台
负责对数据进行报表式处理

工程示例

13

4.1 单元小结

◆ 数据的基本概念与主要特点

**数据技术是信息通信网络的
重要支撑**

14

4.2 数据获取技术

主要内容

4.2.1 数据来源

4.2.2 数据分类

4.2.3 数据采集获取方法

15

4.2.1 数据来源

数据产生方式

被动

被营式系统阶段

- ✓ 根据网络运维和用户行为产生数据
- ✓ 比如装机时提供的位置、业务需求等

主动

用户原创内容阶段

- ✓ 用户：进行网络设计、维护、优化等操作的运行维护技术人员
- ✓ 原创数据：用户工作中主动积累的大量操作日志

自动

感知式系统阶段

- ✓ 网络中部署各种传感器和监测工具
- ✓ 实时收集关于流量模式、信号强度、环境变化等方面的数据

大数据产生的最主要原因

BUPT-JYF

数据主要来源



网管系统采集 01

网络管理系统能够实时监控网络的状态，采集关键性能指标，这些数据对于分析网络流量、预测故障以及优化网络性能至关重要。



仪表测试 02

使用专业的网络测试仪器可以直接测量网络的各项参数，如带宽、延迟、丢包率等。



传感器测量 03

在智能网络环境中，部署的传感器可以监测环境变化对网络性能的影响，如温度、湿度和移动性等。

BUPT-JYF

4.2.2 数据分类

数据按内容和结构分类

数据按内容分包含传感器数据、用户行为数据、社交网络交互数据及移动互联网数据等。

数据按结构分包含各种类型的结构化、半结构化及非结构化的海量数据。

数据包括

- 传感器数据
- 用户行为数据
- 社交网络交互数据
- 移动互联网数据

数据结构

- 结构化
- 半结构化
- 非结构化

智能信息网络

数据分类

变化特性

- 静态数据**
 - 一段时间内不会改变或者改变频率很低的数据
- 动态数据**
 - 频繁更新或改变的数据
- 流数据**
 - 连续流的形式生成和传输的数据
 - 强调时间序列上的顺序性和实时性



历史数据

实时状态数据

传感器数据

实时日志数据流


网络业务交易数据流

智能信息网络

4.2.3 数据采集获取方法

数据采集方法

大数据采集是大数据处理流程的第一步，指从传感器和智能设备、企业在线系统、企业离线系统、社交网络和互联网平台等获取数据的过程。



传感器

智能设备

资源管理系统

网络管理系统

互联网平台



数据采集、存储



数据分析

数据要求

- 完整性
- 准确性
- 及时性
- 一致性

智能信息网络

4.2.3 数据采集获取方法

数据库采集

- ✓ 运营商通过设备网管、资源管理等信息化系统采集网络数据；
- ✓ 可采集实时网络状态，也可离线导出后分析；
- ✓ 多系统协同采集时需要校准不同数据源的时间和空间关系。

系统日志采集

- ✓ 主要是收集网络运维平台日常产生的大量日志数据
- ✓ 供离线和在线的大数据分析系统使用。

感知设备采集

- ✓ 通过传感器、摄像头和其他智能终端自动采集信号、图片或视频。

管控系统采集

- ✓ 通过特定接口实时采集，然后统一分析
- ✓ 查询模式：SNMP等协议，设备对查询指令进行响应
- ✓ 订阅模式：Telemetry，设备周期性主动推送数据

智能信息网络 21

数据存储

分布式文件系统

分布式文件系统是通过网络将分布在多个地点的物理存储资源连接到一起，或是若干不同的逻辑磁盘分区或卷标组合在一起而形成的完整的有层次的文件系统。

智能信息网络 22

分布式文件系统实例

Hadoop分布式文件系统 (HDFS)

分布式存储系统：

HDFS 是一个分布式文件系统，能够处理 PB 级别的数据存储。

高容错性：

通过数据冗余和自动恢复机制，确保数据的高可靠性。

高吞吐量：

优化了大批次数据访问，适合大规模数据集的批处理任务。

主从架构：

HDFS 采用主从 (Master-Slave) 架构。

智能信息网络 23

数据存储

分布式数据库

分布式数据库 (Distributed Database) 是一种数据库管理系统 (DBMS)，其中数据分布在多个物理位置或节点上，但通过网络连接为外部用户和应用程序提供单一数据库的视图。

1 数据分布

分布式数据库是指数据分布在多个物理位置或节点上，而不是集中存储在单一位置。

2 透明性

分布式数据库提供了一种透明性视图，即外部用户感觉不到数据的分布，而是看到一个统一的数据库。

3 自治性

每个节点可以独立地管理和控制其本地数据，但同时也参与全局数据库的管理。

智能信息网络 24

分布式数据库

关键技术

数据分片 (Sharding)

将数据分割成多个片段，分散存储在不同节点上，以提高存储和查询的效率。

复制 (Replication)

数据在多个节点上复制，以提高数据的可用性和读访问的性能。

分布式事务管理

两阶段提交 (Two-Phase Commit, 2PC) 等机制用于确保分布式事务的原子性和一致性。

分布式查询处理

查询被分解为子查询，并在各个节点上并行处理，然后将结果汇总。

智能信息网络 25

分布式数据库

应用场景



大型企业数据库

适用于大型企业，支持海量数据存储和高并发的查询与事务处理。



云计算平台

在云计算环境中，分布式数据库广泛应用以支持大规模数据存储和处理。



实时数据分析

适合实时数据分析和处理，如实时日志分析、推荐系统等。被分解为子查询，并在各个节点上并行处理，然后将结果汇总。



智能信息网络 26

数据存储

云数据库

云数据库是一种数据库服务，它运行在云计算平台上，并由云服务提供商管理和维护。用户可以通过互联网按需访问和使用这些数据库服务，无需关心底层基础设施的管理。

可扩展性: 01

云数据库可以根据需求动态扩展或缩减资源（如存储空间、计算能力），以应对业务量的变化。

高可用性: 02

云数据库通常提供多区域部署和自动故障转移功能，确保数据的可用性和服务的连续性。

弹性: 03

用户只需按实际使用量付费（如按小时、按请求数收费），无需预先购买和维护硬件，实现成本的最优化。

自动化管理: 04

云数据库服务提供商负责数据库的备份、恢复、监控、补丁更新等日常工作，降低用户管理负担。

安全性: 05

云数据库提供多层次的安全措施，包括数据加密、访问控制、网络隔离等，保护用户数据的安全和隐私。

全球分布: 06

云数据库支持跨区域部署，用户可以选择离终端用户最近的数据中心，减少数据传输延迟，提升应用性能。

智能信息网络 27

云数据库应用案例

数据库产品	支持的数据库类型	主要特性	应用场景	服务提供商
RDS	MySQL, SQL Server, PostgreSQL, MariaDB	全球分布、高性能、高可用性、自动化管理	企业ERP系统、电子商务平台、在线游戏	阿里云、华为云、百度云
PolarDB	MySQL, PostgreSQL	云原生、高性能、自动扩展、多区域复制	大规模数据分析、实时查询	阿里云
MongoDB	MongoDB	自动扩展、高可用性、实时监控	内容管理系统、实时分析	阿里云、腾讯云、华为云、百度云
Redis	Redis	全托管、高性能、自动备份	缓存、会话管理、实时竞价	阿里云、腾讯云、华为云、百度云
TDSQL-C	MySQL, PostgreSQL	分布式、高性能、自动扩展	金融交易、电商交易	腾讯云
GaussDB	MySQL, PostgreSQL, Oracle	分布式、高性能、高可用性	金融级交易系统、大规模数据处理	华为云
TSDB	时序数据库	高性能、高并发、低延迟	物联网、工业监控、实时分析	百度云






智能信息网络 28

4.2 单元小结

- ◆ 大数据的主要来源和分类
- ◆ 大数据采集常用几种方法
- ◆ 大数据存储方法

大数据技术是信息通信网络的
重要支撑



29

4.3 智能处理技术

主要内容

- 4.3.1 数据预处理基本概念
- 4.3.2 数据压缩方法与技术
- 4.3.3 数据聚类方法与技术
- 4.3.4 数据降维方法与技术

智能信息网络

30

4.3.1 数据预处理基本概念

数据预处理与分析

- ◆ 数据预处理是对各种“脏数据”进行精细的洗涤和整理，通过相应的处理方式，将数据转化为标准的、干净的、连续的形式。



智能信息网络

31

数据质量问题

遗漏值

0.4815	0.55432	0.198875	0.763948	0.20846
0.761	0.96536	0.063698	0.412894	0.120898
0.4731	0.84405	0.248324	0.083493	0.479325
0.4969	0.72439		0.993124	0.645778
0.2187	0.43086	0.693711	0.043866	0.359372
0.5481	0.74589	0.480894	0.742778	100
0.3067	0.74821	0.75496	0.597665	0.784129
0.2281	100	0.028054	0.953238	0.057859
0.3067	0.12548	0.601713	0.963871	0.199779
0.2886	0.60146	0.01013	0.31715	0.127903
0.307	0.5881	0.6376	0.247576	0.869724
0.2863	0.14648	0.316141	0.115436	0.763269
0.34	0.91736	0.913262	0.893428	0.642144
0.0224	0.97162	0.81842		0.565585
0.0254	0.20989	0.119678	0.98086	0.188463
0.6388	0.85785	0.172174	0.727829	0.193814
0.4321	90	0.848503	0.029518	0.713752
0.7435	0.26334	0.389864	0.462974	0.96926
0.6632	0.28922	0.248769	0.813531	0.516836
0.9241	0.5383	0.663521	0.303448	0.11518
0.5163	0.99657	0.524372	0.373695	0.45825

产生原因

采集过程中由于故障等原因造成的部分数据丢失和空缺。

解决方法

- ✓ **删除变量**：缺失率较高（大于80%）的字段可以直接删除，比如备注
- ✓ **填充**：定值填充、统计量填充、插值法填充、模型填充、哑变量填充

智能信息网络

32

数据质量问题

异常数据

0.4815	0.55432	0.198875	0.763946	0.20846
0.761	0.96536	0.063698	0.412694	0.120698
0.4731	0.84405	0.248324	0.083493	0.479325
0.6969	0.72438	0.093124	0.893124	0.645776
0.2187	0.43088	0.693711	0.043868	0.359372
0.5481	0.74589	0.480894	0.742278	100
0.3067	0.74821	0.75496	0.597565	0.784126
0.2261	100	0.078064	0.955238	0.057859
0.3067	0.12548	0.601713	0.96387	0.199779
0.2866	0.60146	0.01013	0.31715	0.127902
0.307	0.5891	0.6378	0.247576	0.869224
0.2863	0.14648	0.316141	0.115436	0.763269
0.34	0.91736	0.913262	0.893426	0.642144
0.0024	0.97162	0.081842	0.056585	
0.0254	0.20989	0.119878	0.98086	0.188463
0.6389	0.85785	0.172174	0.727829	0.193814
0.4321	96	0.848593	0.028518	0.713752
0.7435	0.26334	0.389864	0.462974	0.96926
0.6632	0.28922	0.248769	0.813531	0.516836
0.9241	0.5063	0.663525	0.303448	0.15518
0.5163	0.99857	0.524372	0.373695	0.45825

产生原因

- “伪异常”：由于特定的网络事件或者运维人员的维护操作产生
- “真异常”：采集过程中的错误造成的不合理数据

判断方法

- 通过统计方法如IQR（四分位距）和标准差来识别离群值

解决方法

- 据离群值的性质和任务需求，可以选择删除或忽略
- 用均值、中位数或基于模型的估计值来替换

33


数据集成与变换

数据集成

- 多个数据源中的数据合并存放在一个一致的数据存储（如数据仓库）中的过程。

数据变换

- 主要是对数据进行规范化处理，将其转换成适当的形式以适应数据分析和挖掘的需要。



多个数据源 → 实体识别 → 冗余属性识别 → 数据抽取、转换和加载 (ETL) → 统一数据库

简单函数变换

- 通过对数据应用简单的数学函数来改变数据的值或范围
- 例如对数转换、平方根转换等。

规范化

- 将数据按比例缩放，使之落入一个小的特定区间，如0到1之间。
- 常见的规范化方法包括最小-最大规范化、零-均值规范化。

连续属性离散化

- 将连续的数据值划分为一系列离散的范围，每个范围对应一个类别。

34

数据规约

数据规约

◆ 数据规约是指通过各种技术手段，减少数据集的大小，同时在很大程度上保留数据的原始信息和完整性。

方法1：维约归

- 减少数据集中的属性或变量数量，从而降低数据的维度。
- 属性子集选择
- 小波变换
- 主成分分析 (PCA)

方法2：数量约归

- 用较小的数据表示形式替代原始数据，减少数据量。
- 参数方法：线性回归、决策树模型
- 非参数方法：直方图、聚类、抽样

35


4.3.2 数据压缩方法与技术

数据压缩

数据压缩是减少数据文件存储空间，去除源文件的原始数据的冗余度的过程。

冗余

- 相同或者相似信息的重复
- 可以在空间范围重复，也可以在时间范围重复
- 可以是严格重复，也可以是以某种相似性重复



36

4.3.2 数据压缩方法与技术

压缩类型

无损压缩

压缩数据可以完全恢复到原始状态，没有信息丢失。

有损压缩

压缩过程中会丢失部分信息，适用于对精度要求不高的场景

代表性算法

✓ Huffman编码
✓ Lempel-Ziv-Welch (LZW) 编码
✓ Run-Length Encoding (RLE)
✓ Deflate
✓ Arithmetic Coding

✓ JPEG (图像压缩)
✓ MPEG (视频压缩)
✓ MP3 (音频压缩)
✓ Wavelet压缩
✓ Vector Quantization

应用场景

→ 文本数据
→ 数据库备份
→ 医学图像

→ 普通图像存储
→ 视频流媒体
→ 音频文件
→ 实时通信

智能信息网络 37

4.3.2 数据压缩方法与技术

传统的故障告警信息处理流程

1. 管理系统发现告警信息

2. 专业网管人员对告警信息进行分析

3. 对故障进行修复，消除此告警

问题：如何对告警信息进行预处理，减少待分析的告警信息数据量？

案例教学

网络告警数量

网络设备故障而产生的实际告警监测数据庞大

当前模式存在的问题

管理平台中设备告警等运维信息迅猛增长，网管人员无法对庞大的告警信息进行高效的分析。
传统人工处理告警信息定位故障的模式已经无法应对！

智能信息网络 38

4.3.2 数据压缩方法与技术

故障告警信息数据分析

不同设备间的告警

一个网络是由大量的设备互连而成，网络中具有连接关系的设备间，若其中一个设备出现异常，则除其本身会产生告警信息，**与其连接的设备也会出现告警信息**

案例教学

同一设备的告警

网络设备中的各部件作为一个协作的整体，一旦有其中部件出现异常，**则此设备中与其关联的部件也会产生告警**

一个故障可能产生多个告警，而这些告警在数据集中具有关联性，可以挖掘这些告警的关联关系，并利用此关联关系对告警数据集进行压缩。

智能信息网络 39

光网络智能故障分析及定位方法流程图

历史告警

当前告警

数据预处理

格式转换

附加标签

统计分析

数据过滤

数据清洗

统计分析

告警压缩

故障定位

聚类

切片

算法

时间窗口

关联规则

定位信息

智能信息网络 40

4.3.2 数据压缩方法与技术

关联分析

告警事务id	告警项
1	a,c,e
2	b,d
3	b,c
4	a,b,c,d
5	a,b
6	b,c
7	a,b
8	a,b,c,e
9	a,b,c
10	a,c,e

- 假如得到如左表所示告警信息，其中，**案例教学**
- 每个字母代表一个告警项，即a,b,c,d,e分别代表一个告警项
 - 不同的项组合在一起形成不同的项集，如{a,b},{b,c},{a,c,e}.....
 - 一段时间内发生的告警事项的集合为一个告警事务，如表中所示事务有10个

问题：这些告警项之间有没有关系（如：告警a发生和告警b, c, e发生之间有没有关联性）？如何确定告警之间的关联性？

4.3.2 数据压缩方法与技术

关联分析又称**关联挖掘**，是数据挖掘领域的一种无监督算法，用于挖掘数据中潜在的属性关联组合规则，目的是寻找给定数据记录集中数据项之间隐藏的关联关系。描述数据之间的密切度，所发现的模式通常用**关联规则**和**频繁项集**的形式表示。

频繁项集

指经常出现在一块的项的集合，如{a,b}。通常用**支持度**来量化项目是否为频繁项集，当项集的支持度大于最小支持度则为频繁项集。

支持度：数据集中包含该项集的记录所占的比例，即该事项出现的次数与总次数出现的比例。

如在表中项集{a,b}的记录5次，数据集事务数为10，所以支持度为 $5/10=0.5$ 。

告警事务id	告警项
1	a,c,e
2	b,d
3	b,c
4	a,b,c,d
5	a,b
6	b,c
7	a,b
8	a,b,c,e
9	a,b,c
10	a,c,e

4.3.2 数据压缩方法与技术

关联分析又称**关联挖掘**，是数据挖掘领域的一种无监督算法，用于挖掘数据中潜在的属性关联组合规则，目的是寻找给定数据记录集中数据项之间隐藏的关联关系。描述数据之间的密切度，所发现的模式通常用**关联规则**和**频繁项集**的形式表示。

关联规则

暗示两种项集之间可能存在很强的关系，通常用**置信度**来衡量。大于置信度阈值则认为是具有关联规则。

置信度是个条件概念，即判断(a)发生的情况下，(b)发生的概率，是针对关联规则（如{a}-->{b}）来定义的。

{a}-->{b}这条规则的置信度为：支持度{a,b}/支持度{a}，右表中{a,b},{a}支持度分别为0.5, 0.7，所以{a}-->{b}这条规则的置信度为 $0.5/0.7=71.4\%$ ，即{a}发生的情况下，{b}发生概率71.4%

告警事务id	告警项
1	a,c,e
2	b,d
3	b,c
4	a,b,c,d
5	a,b
6	b,c
7	a,b
8	a,b,c,e
9	a,b,c
10	a,c,e

4.3.2 数据压缩方法与技术

关联分析及基本概念


关联分析的难点

无论频繁项集还是关联规则都需要计算支持度，需要对每个项集都进行一次**全量数据集扫描**。

对于含N个项的数据集共有 2^N-1 种项集组合，即使4个项也需要遍历数据集15次（组合过程如右图所示），

若有100个项，则有 $2^{100}-1$

$=1.26 \times 10^{30}$ 个项集组合，**计算量过大，实现困难**



四个项的项集组合过程示意图

利用Apriori算法寻找频繁项集，并根据频繁项集之间的关联规则对数据集进行压缩，有效避免项集数目的指数增长！

示例：基于Apriori算法的告警信息数据压缩

算法介绍

Apriori算法（先验算法）：用于挖掘数据集中的**频繁项集**和**关联规则**，属于**无监督学习**

Apriori算法基本思想：

- (1) 寻找频繁项集(大于最小支持度的项集)
- (2) 根据关联性规则对频繁项集进行压缩

数据集

一项的频繁项集 ← 筛选剪枝 ← 一项的项集

组合

两项的频繁项集 ← 筛选剪枝 ← 两项的项集

组合

..... ← 筛选剪枝 ←

组合

K项频繁项集 ← 筛选剪枝 ← K项的项集

[1]Apriori算法详解: <https://zhuanlan.zhihu.com/p/341882260> (后同)

智能信息网络 45

示例：基于Apriori算法的告警信息数据压缩

Apriori算法生成频繁项集过程

- 扫描数据集，从中生成项集 C1。接着调用 Scan 函数扫描 C1，计算其支持度，**支持度大于最小支持度的项集，就是频繁项集 L1。**
- 支持度小于最小支持度的项集为非频繁项集，**由于非频繁项集的所有超集也都是非频繁的。因此，第二轮迭代中，只需要对上一轮迭代产生的频繁项集进行新的组合即可。
- 如此循环，直到没有新组合可生成为止。

数据集

一项频繁项集L1 ← 筛选剪枝 ← 一项的项集C1

组合

两项的频繁项集 ← 筛选剪枝 ← 两项的项集

组合

..... ← 筛选剪枝 ←

组合

K项频繁项集 ← 筛选剪枝 ← K项的项集

智能信息网络 46

示例：基于Apriori算法的告警信息数据压缩

算法流程

- 生成初始项集：**遍历初始的数据集得到只有一项的频繁项集
- 生成备选项集：**用现有频繁项集生成
- 过滤备选项集：**将不符合最小支持度的备选项集过滤
- 频繁项集终止条件判断：**上一个步骤中是否发现新的频繁项集
- 生成真子集：**根据输出的频繁项集得到其所有真子集
- 关联规则判断：**判断其真子集间的关联规则是否符合最小置信度

```

graph TD
    A[生成初始项集] --> B[生成备选项集]
    B --> C[过滤备选项集]
    C --> D{终止条件判断}
    D -- 否 --> B
    D -- 是 --> E[生成真子集]
    E --> F{关联规则判断}
    F --> G[输出强关联规则]
  
```

智能信息网络 47

示例：基于Apriori算法的告警信息数据压缩

待压缩数据集

告警事务id	告警项
1	a, c, e
2	b, d
3	b, c
4	a, b, c, d
5	a, b
6	b, c
7	a, b
8	a, b, c, e
9	a, b, c
10	a, c, e

数据集说明：

左表为一段时间内的告警信息，如表所示共有10个事务。每个事务中的告警项，如a表示的就是1个告警信息，**按照告警名称区分不同的告警**，则此10个事务集中一共有**27个项（即27个告警）**

参数设置：

设置判断条件：频繁项集的**最小支持度为30%**，最小置信度设置为**70%**

案例教学

智能信息网络 48

示例：基于Apriori算法的告警信息数据压缩

算法流程-生成初始项集

告警事务id | 告警项

1	a,c,e
2	b,d
3	b,c
4	a,b,c,d
5	a,b
6	b,c
7	a,b
8	a,b,c,e
9	a,b,c
10	a,c,e

扫描原始数据集计算项集的支持度

C1

项集	支持度
{a}	0.7
{b}	0.8
{c}	0.7
{d}	0.2
{e}	0.3

按照最小支持度过滤得到初始项集

支持度小于阈值，非频繁项集，将被过滤的数据

初始的一项项集

L1

项集	支持度
{a}	0.7
{b}	0.8
{c}	0.7
{e}	0.3

支持度计算公式：
项集A的支持度 = $\frac{\text{项集A在数据集中出现的次数}}{\text{总的事务数}}$

智能信息网络 49

示例：基于Apriori算法的告警信息数据压缩

算法流程-生成备选项集

生成备选项集（第一次）

L1

项集	支持度
{a}	0.7
{b}	0.8
{c}	0.7
{e}	0.3

C2

项集	支持度
{a,b}	0.5
{a,c}	0.5
{a,e}	0.3
{b,c}	0.5
{b,e}	0.1
{c,e}	0.3

由一项的项集生成二项的项集的示意图

智能信息网络 50

示例：基于Apriori算法的告警信息数据压缩

算法流程-过滤备选项集

过滤备选项集（第一次）

告警事务id | 告警项

1	a,c,e
2	b,d
3	b,c
4	a,b,c,d
5	a,b
6	b,c
7	a,b
8	a,b,c,e
9	a,b,c
10	a,c,e

计算项集支持度

C

项集	支持度
{a,b}	0.5
{a,c}	0.5
{a,e}	0.3
{b,c}	0.5
{b,e}	0.1
{c,e}	0.3

按照最小支持度过滤得到二项的频繁项集

终止条件判断：两项的频繁项集不为空，所以继续循环频繁项集的生成过程.....

两项的频繁项集

L2

项集	支持度
{a,b}	0.5
{a,c}	0.5
{a,e}	0.3
{b,c}	0.5
{c,e}	0.3

智能信息网络 51

示例：基于Apriori算法的告警信息数据压缩

算法流程-生成备选项集

生成备选项集（第二次）

L2

项集	支持度
{a,b}	0.5
{a,c}	0.5
{a,e}	0.3
{b,c}	0.5
{c,e}	0.3

C3

项集	支持度
{a,b,c}	0.3
{a,c,e}	0.3
{a,b,e}	0.1
{b,c,e}	0.1

由二项的项集生成三项的项集的示意图

智能信息网络 52

示例：基于Apriori算法的告警信息数据压缩

算法流程-过滤备选项集

过滤备选项集（第二次）

案例教学

告警事务id	告警项
1	a,c,e
2	b,d
3	b,c
4	a,b,c,d
5	a,b
6	b,c
7	a,b
8	a,b,c,e
9	a,b,c
10	a,c,e

计算项集的支持度

C3	
项集	支持度
{a,b,c}	0.3
{a,c,e}	0.3
{a,b,e}	0.1
{b,c,e}	0.1

按照最小支持度过滤得到二项的频繁项集

L3	
项集	支持度
{a,b,c}	0.3
{a,c,e}	0.3
{a,c}	0.3
{b,c,e}	0.1

终止条件判断：三项的频繁项集不为空，所以继续循环频繁项集的生成过程.....

智能信息网络

示例：基于Apriori算法的告警信息数据压缩

算法流程-生成备选项集

生成备选项集（第三次）

案例教学

由三项的项集生成四项的项集的示意图

C4	
项集	支持度
{a,b,c,e}	0.1
空	

按照最小支持度过滤得到二项的频繁项集

终止条件判断：四项频繁项集为空，所以结束频繁项集的生成过程，得到频繁项集

智能信息网络

示例：基于Apriori算法的告警信息数据压缩

算法流程-关联关系建立

案例教学

频繁项集	支持度	真子集
{a,b}	0.5	{a},{b}
{a,c}	0.5	{a},{c}
{a,e}	0.3	{a},{e}
{b,c}	0.5	{b},{c}
{c,e}	0.3	{c},{e}

由(a),(b)形成两个关联规则

序号	关联规则	序号	关联规则
1	a → b	12	c → a,b
2	b → a	13	a,c → b
3	a → c	14	b → a,c
4	c → a	15	b,c → a
5	a → e	16	a → b,c
6	e → a	17	a,c → e
7	b → c	18	e → a,c
8	c → b	19	c,e → a
9	c → e	20	a → c,e
10	e → c	21	a,e → c
11	a,b → c	22	c → a,e

由每个频繁项集的真子集间形成关联规则

智能信息网络

示例：基于Apriori算法的告警信息数据压缩

算法步骤-关联规则判断

案例教学

序号	关联规则	置信度	序号	关联规则	置信度
1	a → b	71.4%	12	c → a,b	42.9
2	b → a	62.5%	13	a,c → b	60%
3	a → c	71.4%	14	b → a,c	37.5%
4	c → a	71.4%	15	b,c → a	60%
5	a → e	42.9%	16	a → b,c	42.9%
6	e → a	100%	17	a,c → e	60%
7	b → c	62.5%	18	e → a,c	100%
8	c → b	71.4%	19	c,e → a	100%
9	c → e	42.9%	20	a → c,e	42.9%
10	e → c	100%	21	a,e → c	100%
11	a,b → c	60%	22	c → a,e	42.9%

关联规则X→Y的置信度计算公式：

$$\text{置信度}(X \rightarrow Y) = \frac{\text{支持度}(X \cap Y)}{\text{支持度}(X)}$$

$$P(Y|X) = \frac{P(XY)}{P(X)}$$

如计算a→b的置信度的公式为：
P(ab)=0.5, P(a)=0.7

$$\text{置信度}(a \rightarrow b) = \frac{0.5}{0.7} = 71.4286\%$$

按照上述公式计算出所有关联规则的置信度

智能信息网络

示例：基于Apriori算法的告警信息数据压缩

算法步骤-关联规则判断

案例教学

序号	关联规则	置信度	序号	关联规则	置信度
1	a → b	71.4%	12	c → a, b	42.9%
2	b → a	62.5%	13	a, c → b	60%
3	a → c	71.4%	14	b → a, c	37.5%
4	c → a	71.4%	15	b, c → a	60%
5	a → e	42.9%	16	a → b, c	42.9%
6	e → a	100%	17	a, c → e	60%
7	b → c	62.5%	18	e → a, c	100%
8	c → b	71.4%	19	c, e → a	100%
9	c → e	42.9%	20	a → c, e	42.9%
10	e → c	100%	21	a, e → c	100%
11	a, b → c	60%	22	c → a, e	42.9%

筛选大于最小置信度70%的关联规则

序号	关联规则	置信度
1	a → b	71.4%
3	a → c	71.4%
6	e → a	100%
8	c → b	71.4%
10	e → c	100%
18	e → a, c	100%
19	c, e → a	100%
21	a, e → c	100%

智能信息网络

示例：基于Apriori算法的告警信息数据压缩

算法步骤-数据集压缩

案例教学

压缩原理：若关联规则X→Y成立，当数据集中事务出现(X,Y)时，由于X关联Y，则用{X}即可以表示{X,Y}

原数据			关联规则	压缩后	
序号	关联规则	置信度		告警事务id	告警项
1	a → b	71.4%	e → a, c	1	e
3	a → c	71.4%	c → b	2	b, d
6	e → a	100%	a → c, a → b	3	c
8	c → b	71.4%	a → b	4	a, d
10	e → c	100%	c → b	5	a
18	e → a, c	100%	e → a, c	6	c
19	c, e → a	100%	a → c, a → b	7	a, b
21	a, e → c	100%	e → a, c	8	b, e
				9	a
				10	e

智能信息网络

示例：基于Apriori算法的告警信息数据压缩

结果分析

案例教学

告警事务id	告警项
1	e
2	b, d
3	c
4	a, d
5	a
6	c
7	a, b
8	b, e
9	a
10	e

压缩后的告警信息数据集的分析效果

以事务1为例，由于告警e发生会伴随着告警a, c的发生，因此网络运维人员对(e)进行分析和对(a, c, e)进行分析的效果是一致的。
所以对压缩后的告警数据集进行分析和对没有压缩后的告警数据集分析的效果是一致的

压缩效果分析

原告警数据集中十个事务共有27个项（即27个告警），压缩后的告警数据集中十个事务共有14个项（告警），压缩率达到48.1%。
Apriori算法能有效的提高网络管理人员对告警分析的效率！

智能信息网络

示例：基于Apriori算法的告警信息数据压缩

小结

案例教学

- 频繁项集与最小支持度
- 关联规则与置信度阈值

- 发现数据集中具有强关联关系的项，而这些具有强关联关系的项往往由一个故障产生；
- 去掉数量级过大的告警信息中的冗余信息，精简数据集，完成告警信息的压缩；
- Apriori算法将具有强关联关系的多个告警可以由此关联告警中的一个或部分告警来进行表示，实现告警信息的压缩。

Apriori算法基本思想：

- 寻找频繁项集(大于最小支持度的项集)
- 根据关联性规则对频繁项集进行压缩

智能信息网络

4.3.3 数据聚类方法与技术

数据聚类

指根据数据的内在性质将数据分成一些聚合类，每一聚合类中的元素尽可能具有相同的特性，不同聚合类之间的特性差别尽可能大

目的

- ✓ 发现数据中的潜在模式
- ✓ 数据压缩和简化
- ✓ 支持分类和预测任务

应用场景


- 市场细分：** 将客户分组以进行个性化营销。
- 图像分析：** 对象识别和分割。
- 生物信息学：** 基因表达数据的聚类分析。
- 网络安全：** 异常行为检测。
- 社交网络分析：** 社区发现和用户行为分析。

智能信息网络 61

数据聚类典型算法

基于距离的聚类	K-均值聚类：	将数据分成K个簇，每个簇的中心点为均值。
	K-中心点聚类：	使用簇内中心点（质心）而非均值。
层次聚类	凝聚层次聚类：	从每个数据点作为一个簇开始，逐步合并相似的簇。
	分裂层次聚类：	从一个大簇开始，逐步分裂成更小的簇。
基于密度的聚类	DBSCAN：	通过密度可达性划分簇，适用于不规则形状的数据。
	OPTICS：	扩展DBSCAN，处理基于密度的层次聚类。
基于图的聚类	谱聚类：	利用图的拉普拉斯矩阵进行聚类。
	Markov Cluster Algorithm (MCL)：	基于随机游走的图聚类算法。

K-means均值算法在接入机房选址中的应用



每个点为一个居民小区的位置
X轴和Y轴分别为经纬度归一化后的坐标

接入机房的优选位置

智能信息网络 62

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类



信源 → 调制复用器 → 发射机 → 传输信道 → 接收机 → 解调解复用器 → 信宿

信号在信道传输过程中会收到传输特性、各种干扰、各类噪声、以及内部干扰等影响，如何快速准确检测传输的信号状态(即，信号判决)，是影响网络传输系统的可靠性的**重要因素

智能信息网络 63

基于K均值算法的逆向调制光通信信号判决方法




图1 逆向调制无线光通信系统框图




图3 采用K均值算法的信号处理流程图




图2 K均值算法流程图




图4 使用K均值算法对样本点进行分流的流程图

智能信息网络 [1]方晓东,徐智勇,汪井源,等.基于K均值算法的逆向调制光通信信号判决方法[J].光通信技术,2021,45(12):46-49 64

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类

案例教学

输入信号x: (0101010111)

调制器

$y=ax+z$

解调器

输出信号: y

K-means

y	判决结果 (0/1)
0.2	?
0.6	?
0.06	?
0.85	?
0.09	?
0.59	?
0.24	?
1.11	?
0.54	?
0.71	?

[1]方晓东, 徐智勇, 汪井源, 等. 基于K均值算法的逆向调制光通信信号判决方法[J]. 光通信技术, 2021, (后同)

智能信息网络 65

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类

案例教学

k-means

一种无监督学习, 迭代求解的聚类分析算法, 通过将数据分为K(K=2)类, 实现对信号0/1的判决。

支持向量机

一种监督学习, 通过寻找超平面将空间数据向量点划分成两类类别

后续讲述

智能信息网络 66

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类

案例教学

➤ 评价指标

- 单类型聚类准确度计算公式: $P_i = \frac{T_i}{R_i}$
- 整体聚类准确度计算公式: $P_s = \frac{\sum_{i=1}^2 T_i}{\sum_{j=1}^2 R_j}$

设 $P_i(1 \leq i \leq 2)$ 是单信号聚类准确度, P_s 为整体聚类准确度。Ti为属于i类且被正确聚类的数量, Ri为实际类型为i的类别的总数目。

智能信息网络 67

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类

案例教学

➤ K-means算法聚类过程

通过设置聚类的中心(图b), 按照每个点到中心的距离(靠近哪个中心点就归为哪一个类别)将数据聚合为几个类别(图c), 再将聚类后的两部分的质心作为新的中心再次进行划分(图d,e), 直到中心位置不再改变, 完成聚类。

原始数据集

设置聚类中心

按照每个点到中心的距离聚合类别

聚类后的两部分的质心作为新的中心

再次按照中心进行划分

中心位置不再改变结束

智能信息网络 68

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类

◆ 设置k(K=2)个聚类中心:选择将信号判决为几个类别, 并设置2个初始的聚类中心

◆ 划分数据集: 将数据集中其它点划分到距离其最近的聚类中心

◆ 计算新的聚类中心: 计算每个划分的子数据集的质心, 并将此质心作为新的聚类中心

◆ 终止条件判断: 当中心坐标不改变或达到循环次数, 完成信号判决; 否则继续循环前两步的操作

案例教学

智能信息网络 69

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类

按照每个点到中心的距离 (靠近哪个中心点就将这个点划分到这个中心点中), 通常采用的是**欧式距离**, 本案例采用欧式距离。

案例教学

本案例只有一维, 所以每个点与中心点的距离的大小应按**一维的欧式距离**来计算

n维坐标下的欧式距离计算公式如下 (x, y 为此n维坐标上的两个点, n 为维度)

$$\text{dist}(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

距离计算的依据

令 x_n 表示待判决数据集中某个点的值的大小, $x_{\#}$ 为某个中心点的值的大小, 则**数据集中点到中心点的计算公式:**

$$\text{dist}(x_n, x_{\#}) = |x_n - x_{\#}|$$

智能信息网络 70

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类

➢ 某个***分析结果, 与原发送信号进行对比

序号	y	判决结果	x
1	0.2	0	0
2	0.6	1	1
3	0.06	1	0
4	0.85	1	1
5	0.09	0	0
6	0.59	0	1
7	0.24	0	0
8	1.11	1	1
9	0.54	1	1
10	0.71	1	1

智能信息网络 71

4.3.3 数据聚类方法与技术

基于K-means算法的网络数据智能判决与聚类

评价指标

- 单类型聚类准确度计算公式: $P_i = \frac{T_i}{R_i}$
- 整体聚类准确度计算公式: $P_s = \frac{\sum_{i=1}^2 T_i}{\sum_{j=1}^2 R_j}$

$P_0 = \frac{T_0}{R_0} = 3/4 = 0.75$ $P_1 = \frac{T_1}{R_1} = 5/6 = 0.83$

$P_s = \frac{T_0 + T_1}{R_0 + R_1} = (3 + 5) / 10 = 0.8$

$P_i (1 \leq i \leq 2)$ 是单信号聚类准确度, P_s 为整体聚类准确度。
 T_i 为属于*i*类且被正确聚类的数量, R_i 为实际类型为*i*的类别的总数目。

序号	y	判决结果	x
1	0.2	0	0
2	0.6	1	1
3	0.06	1	0
4	0.85	1	1
5	0.09	0	0
6	0.59	0	1
7	0.24	0	0
8	1.11	1	1
9	0.54	1	1
10	0.71	1	1

智能信息网络

4.3.3 数据聚类方法与技术

K-means算法优缺点

优点

- 原理比较简单，实现容易，收敛速度快
- 聚类效果较优，算法的可解释性强
- 主要需要调参的参数仅仅是簇数k
- 无监督学习，自适应聚类

缺点

- 对噪声点比较敏感，中心点易偏移
- 差别很大的簇难以进行增量计算
- 不一定是全局最优，可能会陷入局部最优
- 结果与簇个数(K)、初始中心选取、不同的距离计算方式有关

[1]k-means算法原理以及数学知识: https://blog.51cto.com/u_9269309/1864214
 [2]张建平, 刘希玉. 基于聚类分析的K-means算法研究及应用[J]. 计算机应用研究. 2007, 24(5):3.

智能信息网络

4.3.4 数据降维方法与技术

- **数据**: 用于表示客观事物的未经加工的原始素材，是事实或观察的结果。
- **维度**: 一组数据的组织表现形式。
- **数据维度**: 在数据之间形成特定关系，表达多种数据含义的一个很重要的基础概念。
- **一维数据**: 一维数据由对等关系的有序或无序数据构成，采用线性方式组织，数据之间是对等关系；可以用列表、集合、数组表示。
- **二维数据**: 二维数据由多个一维数据构成，是一维数据的组合形式，一般用矩阵或列表表示。
- **高维数据**: 高维数据由一维或二维 (...) 数据在新的维度上扩展形成。

在高维数据的微观层次上分析每一个维度难以实现: 存储数据所需的存储空间随着维度的增加而增加; 维度越小, 训练机器学习模型所需的时间就越少; 随着维度的增加, 过度拟合机器学习模型的可能性也会增加; 难以可视化高维数据。
解决方法-降维: 其本质是删除数据中的所有相关特征, 将数据缩减为一维或二维, 以实现更好的可视化。

智能信息网络

4.3.4 数据降维方法与技术

示例: 信息网络中如此复杂巨大的数据量, 如何处理? 数据的**降维处理** (维度: 数据集中特征的数量)-

Sample-1 Sample-2 Sample-3 Sample-4 Sample-5 Sample-6

Feature-1	Sample-1	Sample-2	Sample-3	Sample-4	Sample-5	Sample-6
Feature-1	10	11	8	3	2	1

Sample-1 Sample-2 Sample-3 Sample-4 Sample-5 Sample-6

Feature-1	Sample-1	Sample-2	Sample-3	Sample-4	Sample-5	Sample-6
Feature-1	10	11	8	3	2	1
Feature-2	6	4	5	3	2.8	1
Feature-3	3.2	9	1.0	2.5	1.8	2

N维? 高维数据可视化?
 采用降维的2种方法:
 特征选择; 特征投影

Sample-1 Sample-2 Sample-3 Sample-4 Sample-5 Sample-6

Feature-1	Sample-1	Sample-2	Sample-3	Sample-4	Sample-5	Sample-6
Feature-1	0.45054	1.07435	-0.93872	-0.75346	0.51374	
Feature-2	0.08532	0.97882	0.25259	0.35445	-1.0334	
Feature-3	0.11736	0.97521	0.91275	-0.68896	0.16857	
Feature-4	0.98279	-0.38041	0.67127	-0.1952	0.27778	
Feature-5	-0.7285	0.95352	-0.67247	0.96088	-0.5285	
Feature-6	1.89432	-0.6544	0.46531	1.08352	0.32332	

Sample-1 Sample-2 Sample-3 Sample-4 Sample-5 Sample-6

Feature-1	Sample-1	Sample-2	Sample-3	Sample-4	Sample-5	Sample-6
Feature-1	0.45054	1.07435	-0.93872	-0.75346	0.51374	0.45944
Feature-2	0.08532	0.97882	0.25259	0.35445	-1.0334	0.08532
Feature-3	0.11736	0.97521	0.91275	-0.68896	0.16857	0.11736
Feature-4	0.98279	-0.38041	0.67127	-0.1952	0.27778	0.98279
Feature-5	-0.7285	0.95352	-0.67247	0.96088	-0.5285	-0.7285
Feature-6	1.89432	-0.6544	0.46531	1.08352	0.32332	1.89432

机器学习: 降维技术完整指南, <https://baijiahao.baidu.com/s?id=166441921056092568&wfr=spider&for=pc> (后同)

智能信息网络

4.3.4 数据降维方法与技术

特征选择: 单纯地从所有特征中选择部分特征作为新的特征, 选择后的特征是原始特征的子集。方法: 特征理解, 模型选择, 减少特征, 删除相关特征等。
特征投影: 将原始高维特征空间里的点向一个低维空间投影, 投影后的特征是原始特征的线性组合。

类型	方法	特点
特征选择	Filter (过滤法)	按照发散性或者相关性对各个特征进行评分, 设定阈值或者选择阈值的个数, 选择特征。
	Wrapper (包装法)	根据目标函数 (通常是预测效果评分), 每次选择若干特征, 或者排除若干特征。
	Embedded (嵌入法)	先使用某些机器学习的算法和模型进行训练, 得到各个特征的权值系数, 根据系数从大到小选择特征。类似于Filter方法, 但是是通过训练来确定特征的优劣。
特征投影	<u>PCA (主成分分析法)</u>	删除了相关特征, 提高了模型效率, 减少过度拟合, 改善可视化效果
	LDA (线性判别分析法)	在降维过程中可以使用类别的先验知识经验

特征工程: https://blog.csdn.net/yellow_w/article/details/118229797

智能信息网络

4.3.4 数据降维方法与技术

主成分分析介绍

- 主成分分析是一种常用的降维方法，通过某种线性投影，将高维空间中的多变量转化到低维空间中，形成新的少数的变量，并期望在所投影的维度上数据的信息量最大（方差最大）；
- 主成分分析降维的过程就是寻找数据最佳拟合曲线的过程；
- 降维形成的少数新变量即为主成分，主成分与最佳拟合曲线为——对应的关系，几个主成分对应几条拟合曲线；
- 各拟合曲线之间两两相互正交。

两维图例说明

	Sample-1	Sample-2	Sample-3	Sample-4	Sample-5	Sample-6
Feature-1	10	11	8	2	2	1
Feature-2	6	4	5	3	2.8	1

两维数据——两个主成分——两条拟合线
PC1与PC2正交

难点：如何找到最佳拟合线？

4.3.4 数据降维方法与技术

示例：主成分分析（PCA）-以2维降1维为例

问题：PCA是如何找到最佳拟合线的？

案例教学

对数据进行归一化处理，使平均值移动到原点

用一条线来拟合数据，旋转直线直到它最适合数据为止

为了确定直线与数据的匹配程度，PCA将数据投影到直线上

找到最佳拟合线，以使从投影点到原点的距离平方的总和最大

根据勾股定理，B和C彼此成反比，如果C变大B必须变小

$D = \arg \max_A \sum_{i=0}^n (d_i^2)$

PCA 成本函数

$A^2 = B^2 + C^2$

(1) 最小化点到直线的距离总和；
(2) 最大化投影点到原点的距离

4.3.4 数据降维方法与技术

主成分PC1的求解

案例教学

最佳拟合线 $y = mx + c$ ，称为PC1（主成分1）

假设比例为4:1，即在X轴上移动4个单位，在Y轴上移动1个单位，这说明数据大部分分布在X轴上

$a^2 = b^2 + c^2 \Rightarrow a^2 = 4^2 + 1^2 \Rightarrow \sqrt{17} \Rightarrow 4.12$

按比例缩放，将每一边除以4.12，以获得单位向量。即

$F1 = 4 / 4.12 = 0.97$
 $F2 = 1 / 4.12 = 0.242$

单位向量称为特征向量或PC1

$SS(PC1 \text{ 的距离}) = PC1 \text{ 的特征值}$

令SS为离差平方和，表示各项与平均项之差的平方的总和：

$$SS = \sum_{i=1}^n (x_i - \bar{x})^2$$

x_i 是第*i*个数据， $\bar{x}$ 是均值， $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

4.3.4 数据降维方法与技术

主成分方差的求解

案例教学

对其他特征做同样的事情得到主成分PC2。
旋转轴，使PC1变为水平

根据主成分投影数据

使用在PCA中计算的特征值来计算方差

方差 $D(X)$ (Variation for PC1/PC2)：用来度量数据和其即均值之间的偏离程度，是对每个数据与所有数据的均值之差的平方求平均。

$D(X) = \frac{SS}{n-1} = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{1}{n-1} [(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2]$

$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ， n 是每个维度数据个数

$\frac{SS(\text{distances for PC1})}{n-1} = \text{Variation for PC1}$

$\frac{SS(\text{distances for PC2})}{n-1} = \text{Variation for PC2}$

4.3.4 数据降维方法与技术

主成分方差的求解

案例教学

$$D(PC1) = \frac{SS_{PC1}}{n-1} = \frac{\sum_{i=1}^n (x_{1i} - \bar{x}_1)^2}{5} = 18.97$$

$$D(PC2) = \frac{SS_{PC2}}{n-1} = \frac{\sum_{i=1}^n (x_{2i} - \bar{x}_2)^2}{5} = 3.126$$

$$D(PC1) = \frac{D(PC1)}{D(PC1)+D(PC2)} = 0.86(\text{归一化})$$

$$D(PC2) = \frac{D(PC2)}{D(PC1)+D(PC2)} = 0.14(\text{归一化})$$

$D(PC1) > D(PC2)$, 所以选择PC1作为主成分 (覆盖了86%)。

最终实现2维降1维

	Sample-1	Sample-2	Sample-3	Sample-4	Sample-5	Sample-6
Feature-1	10	11	8	3	2	1
Feature-2	6	4	5	3	2.8	1

智能信息网络

81

4.3.4 数据降维方法与技术

主成分分析小结

案例教学

最大方差理论: 在信号处理中认为信号具有较大的方差, 噪声有较小的方差, 方差越大说明数据的有效信息越多。

方差代表数据和其均值之间的偏离程度以及数据的变异程度, 对数据样本来说, **采样方差越大, 涵盖数据信息越完整**

主成分分析PCA根据主成分的方差估计需要消除的特征, 从而进行降维。

优点: 删除了相关特征, 提高了模型效率, 减少过度拟合, 改善可视化效果。

缺点: 选取的主成分数据是原始特征数据的线性组合, 因此可解释性较低。

智能信息网络

82

4.3.4 数据降维方法与技术

网络拓扑

工程示例

流量矩阵 $t_{(i,j)}$ 第 i 行第 j 列的元素, 其意义为网络中节点 i 到节点 j 之间的流量。

例如: $t_{(2,3)}$ 的数值为14512, 代表节点2到节点3的流量为14512。

流量矩阵 $t_{(i,j)}$ (某一时刻的流量矩阵)

	1	2	3	4	5	6	7	8	9	10	11	12
1	19879	3664.5	5779.4	20614	2951.7	1275.3	6087.1	10695	72279	16304	8407.4	144.49
2	63910	16044	14512	29616	735.49	579.73	1716.4	491.62	7612.1	2276	1303.3	39.789
3	6601.6	8954.6	4150.7	6952.1	12220	10334	24905	6709.9	74133	16903	42634	163.63
4	25334	15647	8738.6	14530	7610.6	5689.1	31773	15431	1.4027e+005	56236	81135	2159.1
5	4141.3	2495.9	9357.5	5495.6	5207.1	2695.4	9559.6	4839.2	41426	7496.3	9457.6	1617.7
6	4245	1934.3	6891.5	1.0079e+005	1416.6	8932.3	5296.2	5114.2	37613	8210.6	7669.7	920.96
7	11361	3140.8	24949	85249	10941	3330.4	19616	10897	1.1809e+005	33029	46437	500.49
8	4509.6	993.16	5001.1	15451	3060.3	1619.1	17362	71139	15820	13036	30211	173.06
9	4893.3	3281.9	6036.6	20647	5963.8	4231.8	17635	8583.9	43595	5004.1	12724	53.654
10	19244	7947.9	30551	62408	12848	23061	37066	29509	58932	1.467e+005	63439	391.42
11	33686	16086	49705	60012	11039	17252	48416	95504	74811	1.4318e+005	3.0315e+005	18571
12	224.47	161.72	0	628.87	294.54	336.14	310.6	454.84	1095	476.91	3784.4	0

S: 丁关关. 基于主成分分析的网络流量异常检测研究[D](后同)

智能信息网络

83

4.3.4 数据降维方法与技术

网络拓扑

工程示例

流量数据 (12个时刻)





T_k 代表第 k 个时刻
 $t_{(i,j)}$ 代表第 i 行第 j 列的流量数据

时刻 流量	T_1	T_2	T_3	...	T_{12}
$t_{(1,1)}$					
$t_{(1,2)}$					
...					
$t_{(12,12)}$					

- 一个12点的网络拓扑, 其流量矩阵为 12×12 矩阵。
- 若统计12个时刻的流量数据, 则流量数据为 144×12 。
- 任意两点间的流量 $t_{(i,j)}$ 看作一个流量数据维度, 则流量数据具有144维。
- 采用降维的方法对网络流量进行分析, 能够用合适维度的空间来完好地解析原始网络流量空间的特征, 减小计算复杂度。

智能信息网络

84





4.4.1 数据可视化定义

◆ 数据可视化的标准

可视化技术应用标准应该包含以下5个方面：

- 1) **真实性**：可视化结果应该正确反映数据的本质；
- 2) **直观化**：将数据直观、形象的呈现出来，有利于人们认知数据背后所蕴涵的现象和规律；
- 3) **关联化**：突出的呈现出数据之间的关联性；
- 4) **艺术性**：使数据的呈现更具有艺术性，更加符合审美规则，使可视化结果的形式与内容和谐统一；
- 5) **交互性**：实现用户与数据的交互，方便用户控制数据。



4.4.2 数据可视化工具

大数据可视化工具必须具有以下特性：


- ① **实时性**：数据可视化工具必须适应大数据时代数据量的爆炸式增长需求，必须快速地收集分析数据、并对数据信息进行实时更新；
- ② **简单操作**：数据可视化工具满足快速开发、易于操作的特性，能满足互联网时代信息多变的特点；
- ③ **更丰富的展现**：数据可视化工具需具有更丰富的展现方式，能充分满足数据展现的高维度要求；
- ④ **交互性**：允许用户选择感兴趣的内容，或者改变数据的展示形式，更好的促进用与数据之间的互动；
- ⑤ **多种数据集成支持方式**：数据的来源不仅仅局限于数据库，数据可视化工具将支持团队协作数据、数据仓库、文本等多种方式，并能够通过互联网进行展现。



4.4.2 数据可视化工具

图表设计过程



图表设计的目的是通过图表的视觉表现形式，直观、清晰、准确的展示已知多数据或单数据的联系。








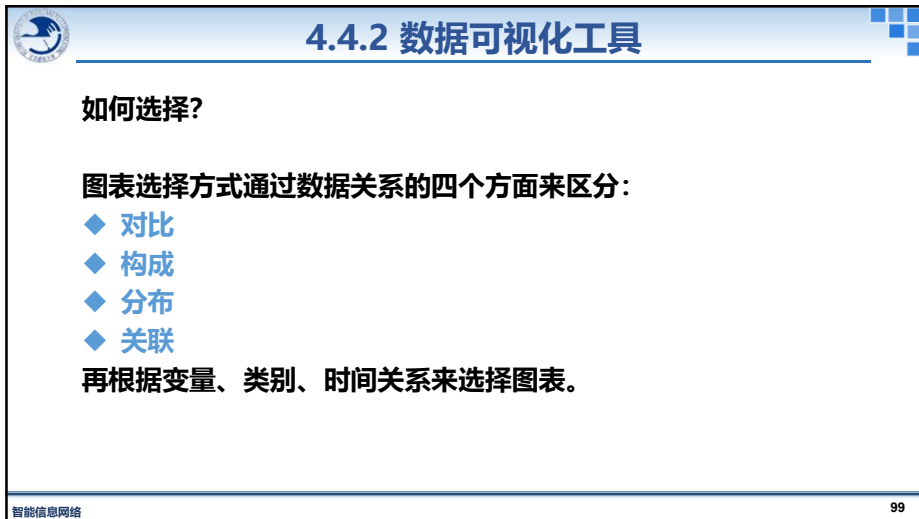

4.4.2 数据可视化工具



① 柱状图 (Bar Chart)

柱状图是最常见的图表，也最容易解读。它的适用场合是二维数据集（每个数据点包括两个值x和y），但只有一个维度需要比较。仅适用于中小规模的数据集。











4.4 单元小结



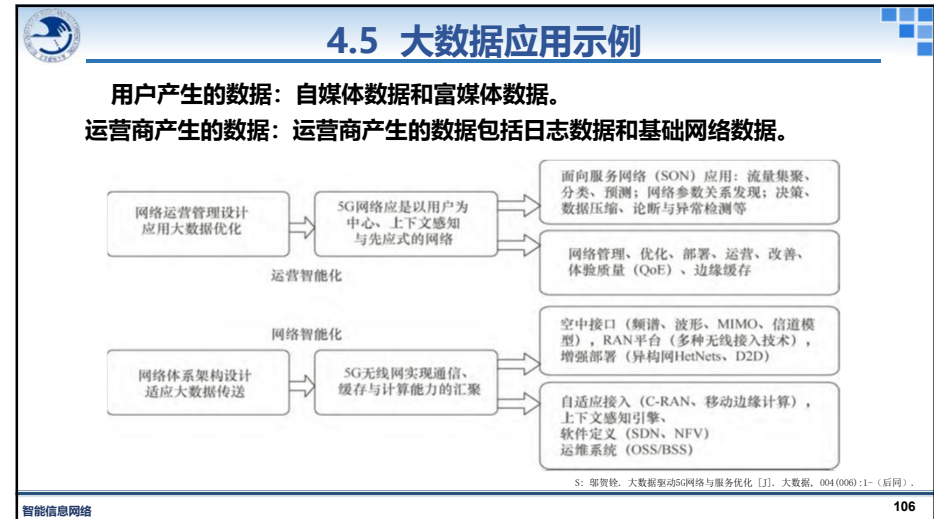

◆ 数据可视化的概念、方法与适用性

大数据技术是信息通信网络的重要支撑



智能信息网络 103







第4章 小结

1. 数据的基本概念与特征
2. 网络数据获取技术
3. 数据智能处理方法
4. 数据可视化方法
5. 大数据应用



智能信息网络
109



第4章 思考题

- 4.1 什么是大数据？浅析其关键技术。
- 4.2 说明数据分析与处理能给智能信息网络带来什么？
- 4.3 请简述数据压缩、数据聚类、数据降维等技术实现的基本原理。
- 4.4 请阐述常用的数据可视化方法，及其适用场景。
- 4.5 除柱状图、折线图、饼图、散点图、气泡图、雷达图外，
还有哪些可视化的图表（形式）？
- 4.6 举例说明大数据应用场景。



智能信息网络
110



智能 + 网络 = ?

你说 我说 大家说

THANKS

