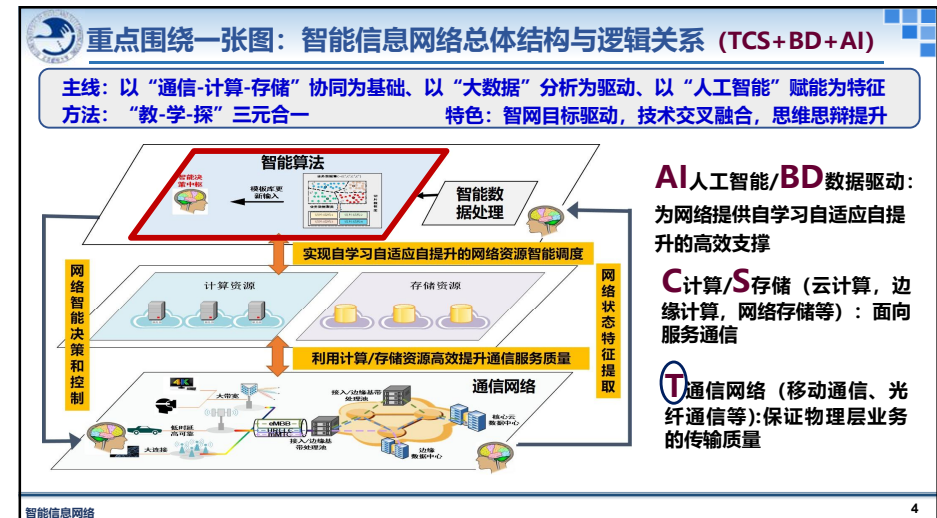




教学内容		
智能信息网络	1	智能信息网络概述
	2	高速宽带信息网络技术 (基础篇)
	3	信息网络性能分析技术 (基础篇)
	4	网络数据的智能处理技术 (基础篇)
	5	网络中常用的智能算法 (基础篇)
	6	网络智能规划 (应用篇)
	7	网络智能部署 (应用篇)
	8	网络智能运维 (应用篇)
	9	网络智能优化 (应用篇)
	10	智能信息网络发展前景





第5章 主要参考资料

1. 周志华, 机器学习[M], 清华大学出版社, 2016
2. 雷明. 机器学习与应用[M]. 北京: 清华大学出版社, 2019.

智能信息网络 5



第5章 内容提要

5

5.1 人工智能与机器学习基本概念

5.2 网络中机器学习典型算法

问题:

1. 如何分析和处理数据?
2. 数据能给通信网络带来什么?

智能信息网络 6



第5章 学习目标与教学思路

- ◆ 掌握基本智能算法的概念
- ◆ 掌握不同算法的基本原理
- ◆ 了解不同算法的应用场景

3要点: 基本概念, 基本原理, 应用场景

智能信息网络 7



5.1 人工智能与机器学习基本概念


主要内容

5.1.1 人工智能基础

5.1.2 机器学习算法分类

智能信息网络 8

5.1.1 人工智能基础



人工智能 (Artificial Intelligence, AI), 是**研究、开发**用于**模拟、延伸**和**扩展人的智能**的理论、方法、技术及应用的**技术科学**

- ▶ **大数据:** 人工智能的智能, 蕴含在大数据中
- ▶ **算力:** 算力为人工智能提供了基本的计算能力的支撑
- ▶ **算法:** 算法是实现人工智能的根本途径, 是挖掘数据智能的有效方法
- ▶ **场景:** 大数据、算力、算法作为输入, 只有在实际的场景中进行输出, 才能体现出实际的价值


dyna_idan: 人工智能技术--四要素分析, https://blog.csdn.net/dyna_idan/article/details/82229313 (后同)

智能信息网络 9

5.1.1 人工智能基础

示例: 智能流量预测

人工智能与通信



示例: 基于人工智能的流量预测, 可以按需调节带宽、计算等资源分配; 减少不必要的资源浪费。

智能信息网络 10

5.1.1 人工智能基础

机器学习定义

机器学习(Machine Learning)是计算机科学的子领域, 是人工智能的一个分支和实现方式。

机器学习主要的理论基础涉及到概率论、数理统计、数值逼近、最优化理论、计算复杂理论等, 核心要素是数据、算法和模型。

智能信息网络 11

5.1.1 人工智能基础: 基本术语

- 数据集 (Dataset)**
 - 定义: 一组数据的集合。
 - 解释: 数据集是由多个样本组成的, 每个样本代表一个事件或对象, 包含多个特征。
- 样本/特征向量 (Sample/Feature Vector)**
 - 定义: 数据集的任一事件或对象, 由多个特征共同组成。
 - 解释: 每个样本可以用一个特征向量来表示, 特征向量中的每个元素对应一个特征的值。
- 特征/属性 (Feature/Attribute)**
 - 定义: 反映事件或对象在某方面表现或性质的事项。
 - 解释: 特征是描述样本的属性, 例如, 一个人的身高、体重、年龄等。
- 特征空间 (Feature Space)**
 - 定义: 每个特征表示坐标的一个维度, 多个特征共同组成的多维空间。
 - 解释: 特征空间是一个多维空间, 每个维度代表一个特征, 样本在这个空间中以点的形式存在。

智能信息网络 12

5.1.1 人工智能基础：基本术语

模型 (Model)

- ❖ **定义：**对数据潜在规律的数学或算法表示
- ❖ **解释：**指一种数学或算法结构，用于从数据中学习规律，并对新的数据进行预测或分类。模型是实现人工智能任务的核心工具，通过训练和优化，模型能够从大量数据中提取特征，发现潜在模式，并应用于实际问题中
- ❖ **作用：**
 - 预测：基于已知数据，预测未来或未知的数据。
 - 分类：将数据划分为不同的类别。
 - 聚类：发现数据中的自然分组。
 - 回归：预测连续数值。
 - 生成：生成新的数据样本。

模型与算法的区别

- ❖ **模型：**是指整个系统或框架，用于表示数据的潜在规律。
- ❖ **算法：**是指具体实现模型训练和预测的方法或步骤。
- ❖ 例如，线性回归是一种模型，而梯度下降是一种优化算法，用于训练线性回归模型。

智能信息网络 13

5.1.1 人工智能基础：基本术语

假设 (Hypothesis)

- 定义：模型中得到的某种潜在规律。
- 解释：假设是模型对数据潜在规律的推测，用于对新样本进行预测或分类。

假设空间

- 定义：所有可能的模型或假设的集合
- 解释：在寻找最佳模型时所遍历的范围，它既包括了可能的正确答案，也包括了那些最终被证明是错误的假设。在这一系列假设中，每一个假设都代表了一个特定的解决问题的策略或模型，它定义了学习的潜力和边界。

真相/真实 (True/Reality)

- 定义：潜在的规律本身。
- 解释：真相是数据背后的真实规律，模型的目标是通过学习数据来逼近真相。

智能信息网络 14

5.1.1 人工智能基础：基本术语

目标变量 (Target Variable)

- 定义：模型需要预测或分类的变量。
- 解释：目标变量是数据集中需要预测或分类的特征，通常是一个结果或标签。例如，“是否选择”

正样本 (Positive Example) :

- 定义：目标变量为正类的样本。
- 解释：正样本是属于目标变量正类的样本。例如，目标变量为“是”的样本就是正样本。

负样本 (Negative Example) : 负样本

- 定义：目标变量为负类的样本。
- 解释：负样本是属于目标变量负类的样本。例如，目标变量为“否”的样本就是负样本。

智能信息网络 15

5.1.1 人工智能基础：基本术语

训练/学习 (Training/Learning)

- 定义：通过数据学习得到模型的过程。
- 解释：训练或学习是指利用训练数据，通过算法调整模型参数，使其能够更好地拟合数据。

训练数据 (Training Data)

- 定义：训练使用的数据，其中每个样本称为一个训练样本。
- 解释：训练数据是用于训练模型的数据集，模型通过分析这些数据来学习规律。

训练集 (Training Set)

- 定义：训练样本组成的集合。
- 解释：训练集是训练数据的具体实现，通常是从数据集中划分出的一部分数据用于模型训练。

学习过程 (Learning Process)

- 定义：在所有假设空间中进行搜索，目标是找到与训练集“匹配”的假设，即找出真相或者逼近真相。
- 解释：学习过程是通过算法在假设空间中搜索，寻找能够最好地拟合训练数据的假设。

泛化 (Generalization)

- 定义：学得模型适应新样本的能力。
- 解释：泛化能力是指模型在未见过的数据上表现良好的能力，是模型性能的重要指标。

智能信息网络 16

5.1.1 人工智能基础

假设空间

问题：源节点S到目的节点D有多条备选路由，具体

路由	容量	时延	功耗	是否选择
1	大	小	少	是
2	中	中	多	否
3	小	大	中	否

(容量=?) $\wedge$ (时延=?) $\wedge$ (功耗=?) $\leftrightarrow$ 可选

设立假设空间，其大小为： $n_1 \times n_2 \times n_3 + 1$ ， n_i 为第*i*个特征的取值数量

空集，所要达到的目标不成立

路由如何选择：搜索假设空间，不断删除与正样本不一致和与负样本一致的假设，最终会得到与训练集匹配的假设，即能够将训练集中的“路由”判断正确的假设（学习结果）。

● 网络节点
■ 交换节点

智能信息网络 17

5.1.1 人工智能基础

版本空间

版本空间(version space)：现实中的实际问题会面临很大的假设空间，但学习过程是基于有限样本训练集进行的。因此，可能会存在多个假设与训练集匹配，将与训练集相匹配的假设空间称之为版本空间 (version space)

容量=*; 时延=小; 功耗=* 容量=*; 时延=*, 功耗=少

* 为通配符，指取什么值都可以

样本：容量=*; 时延=小; 功耗=少

问题：如何得到版本空间？

智能信息网络 18

5.1.1 人工智能基础

【示例】如果表中只包含两个样本，试给出相应的版本空间？

路由	容量	时延	功耗	是否选择
1	大	短	少	是
2	中	长	多	否

【解】

假设数据集有*n*种属性，第*i*个特征属性可能的取值有 t_i 种，加上该属性的泛化取值(*)，所以可能的假设有 $\prod_i (t_i + 1)$ 。再用空集表示没有正样本，假设空间中一共 $\prod_i (t_i + 1) + 1$ 种假设。

如上表：路由数据集有*n*=3个属性，每个属性2种取值，假设空间中一共有 $3 \times 3 \times 3 + 1 = 28$ 种假设。

智能信息网络 19

5.1.1 人工智能基础

【示例】如表中只包含两个样例，试给出相应的版本空间？

路由	容量	延时	功率消耗	是否选择
1	大	短	少	是
2	中	长	多	否

假设空间为属性所有可能取值组成的可能样本， $3 \times 3 \times 3 + 1 = 28$ 种假设如下：

- 容量=* 延时=* 功耗=* ;
- 容量=大 延时=* 功耗=* ;
- 容量=中 延时=* 功耗=* ;
- 容量=* 延时=短 功耗=* ;
- 容量=* 延时=长 功耗=* ;
- 容量=* 延时=* 功耗=少 ;
- 容量=* 延时=* 功耗=多 ;
- 容量=大 延时=短 功耗=* ;
- 容量=大 延时=长 功耗=* ;
- 容量=中 延时=短 功耗=* ;
- 容量=中 延时=长 功耗=* ;
- 容量=大 延时=* 功耗=少 ;
- 容量=大 延时=* 功耗=多 ;
- 容量=中 延时=* 功耗=少 ;
- 容量=中 延时=* 功耗=多 ;
- 容量=* 延时=短 功耗=少 ;
- 容量=* 延时=短 功耗=多 ;
- 容量=* 延时=长 功耗=少 ;
- 容量=* 延时=长 功耗=多 ;
- 容量=大 延时=短 功耗=少 ;
- 容量=大 延时=短 功耗=多 ;
- 容量=大 延时=长 功耗=少 ;
- 容量=大 延时=长 功耗=多 ;
- 容量=中 延时=短 功耗=少 ;
- 容量=中 延时=短 功耗=多 ;
- 容量=中 延时=长 功耗=少 ;
- 容量=中 延时=长 功耗=多 ;
- 空集

智能信息网络 20

5.1.1 人工智能基础

路由	容量	延时	功率消耗	是否选择
1	大	短	少	是
2	中	长	多	否

版本空间从假设空间中剔除与正样本不一致和与负样本一致的假设，看成是对正样本的最大泛化。版本空间求法如下：

首先，剔除与正样本不一致的情况，即删除掉“容量=大 延时=短 功耗=少”不满足(至少一个特征不符)的假设：

容量=*	延时=*	功耗=*
容量=大	延时=*	功耗=*
容量=中	延时=*	功耗=*
容量=*	延时=短	功耗=*
容量=*	延时=长	功耗=*
容量=*	延时=*	功耗=少
容量=*	延时=*	功耗=多
容量=大	延时=短	功耗=*
容量=大	延时=长	功耗=*
容量=中	延时=短	功耗=*
容量=中	延时=长	功耗=*
容量=*	延时=短	功耗=少
容量=*	延时=短	功耗=多
容量=*	延时=长	功耗=少
容量=*	延时=长	功耗=多

智能信息网络 21

5.1.1 人工智能基础

路由	容量	延时	功率消耗	是否选择
1	大	短	少	是
2	中	长	多	否

版本空间从假设空间中剔除与正样本不一致和与负样本一致的假设，看成是对正样本的最大泛化。版本空间求法如下：

其次，剔除与负样本一致的情况，即删除掉“容量=中 延时=长 功耗=多”满足的假设：

容量=*	延时=*	功耗=*
容量=大	延时=*	功耗=*
容量=中	延时=*	功耗=*
容量=*	延时=短	功耗=*
容量=*	延时=长	功耗=*
容量=*	延时=*	功耗=少
容量=*	延时=*	功耗=多
容量=大	延时=短	功耗=*
容量=大	延时=长	功耗=*
容量=中	延时=短	功耗=*
容量=中	延时=长	功耗=*
容量=*	延时=短	功耗=少
容量=*	延时=短	功耗=多
容量=*	延时=长	功耗=少
容量=*	延时=长	功耗=多

智能信息网络 22

5.1.1 人工智能基础

【示例】如表中只包含两个样例，试给出相应的版本空间？

路由	容量	延时	功率消耗	是否选择
1	大	短	少	是
2	中	长	多	否

剔除掉与正样本不一致和与负样本一致的假设，剩下的假设共同组成版本空间（7种）：

容量=大 延时=短 功耗=少；	容量=大 延时=短 功耗=*
容量=大 延时=*	容量=*
容量=大 延时=*	容量=*
容量=*	容量=*

正样本：容量大、时延短、功耗少(期望目标)，从这个样本开始泛化：

只要容量大，时延和功耗取正样本值或泛化值

只要时延短，容量和功耗取正样本值或泛化值

只要功耗少，容量和时延取正样本值或泛化值

智能信息网络 23

5.1.1 人工智能基础

数据集

训练集 (Training Dataset)：用于训练模型。

验证集 (Validation Dataset)：用于对模型的能力进行初步评估，调整模型超参数，监控是否过拟合。

测试集 (Test Dataset)：用于评估模型最终的泛化能力。

机器学习训练步骤：

- Step 1 收集数据
- Step 2 数据处理
- Step 3 选择模型
- Step 4 训练模型
- Step 5 评估模型
- Step 6 参数调整
- Step 7 预测

说明：

- 验证集是非必需的。若不需要调整超参数，可以直接用测试集来评估效果。
- 验证集评估的并非是模型的最终效果，仅用于调整超参数，模型最终效果以测试集的评估结果为准。
- 通过测试集的评估，我们会得到一些最终的评估指标，例如：准确率、精确率、召回率等。

S: 一文看懂 AI 训练集、验证集、测试集, https://blog.6cto.com/a_16282017/3970076 (后两)

智能信息网络 24

5.1.1 人工智能基础

数据集划分原则

留出法：按照固定比例将数据集静态的划分为训练集、验证集、测试集（6:2:2或8:1:1）。

留一法：每次的测试集只有一个样本，进行 m 次训练和预测。该方法用于训练的数据只比整体数据集少了一个样本，因此最接近原始样本的分布。但是训练复杂度增加了，因为训练模型的数量与原始数据样本数量基本相同。一般在数据缺乏时使用。

k 折交叉验证：静态的留出法对数据的划分方式比较敏感，有可能不同的划分方式得到了不同的模型。k 折交叉验证是一种动态验证的方式，可以降低由于数据划分带来的不良影响。



S: 一文看懂 AI 训练集、验证集、测试集, https://blog.51cto.com/u_16282017/2970075 (后两)

智能信息网络 25

5.1.1 人工智能基础

留出法

留出法的数据划分的方法没有明确的规定，可以参考3个原则：

- ◆ 对于小规模样本集（几万量级），常用的分配比例是 60% 训练集、20% 验证集、20% 测试集。
- ◆ 对于大规模样本集（百万级以上），只要验证集和测试集的数量足够即可，例如有 100w 条数据，那么留 1w 验证集，1w 测试集即可。1000w 的数据，同样留 1w 验证集和 1w 测试集。
- ◆ 超参数越少，或者超参数很容易调整，那么可以减少验证集的比例，更多的分配给训练集。


智能信息网络 26

5.1.1 人工智能基础

K折交叉验证

k 折交叉验证是一种动态验证的方式，可以降低由于数据划分带来的不良影响。具体步骤如下：

- 1.将数据集分为训练集和测试集，将测试集先放在一边
- 2.将训练集（样本）随机、均匀分为 k 份
- 3.每次使用 k 份中的 1 份作为验证集（测试模型的准确率性），其他全部作为训练集
- 4.通过 k 次训练后，我们得到了 k 个不同的模型
- 5.评估 k 个模型的效果，从中挑选效果最好的超参数（或用 k 个准确率的均值作为最终的准确值等）
- 6.使用最优的超参数，然后将 k 份数据全部作为训练集重新训练模型，得到最终模型



智能信息网络 27

5.1.1 人工智能基础


归纳偏好

由于版本空间的存在，可能导致面临新样本的时候，会产生截然不同的结果。需要一定的策略对学习结果作出选择，这种策略就是**归纳偏好**，相当于模型的一种“价值取向”。

一般原则：简单有效原理

即：若有多个假设与观察一致，则选**最简单**的那个

并且假设认为，更**平滑**意味着更简单



任何一个有效的机器学习算法必有其偏好

学习算法的归纳偏好是否与问题本身匹配，大多数时候直接决定了算法能否取得好的性能

智能信息网络 28

5.1.2 机器学习算法分类

机器学习分类

机器学习根据学习范式分类，分为以下三种：

监督学习：计算机获得简单的输入给出期望的输出，过程是通过一个“训练模型”，学习通用的准则来从输入映射到输出。

无监督学习：没有给出标记用来学习算法，让它自己去发现输入的结构。无监督学习自己可以被当成一个目标或者一个实现结果的途径（特征学习）。

半监督学习：是监督学习与无监督学习相结合的一种学习方法。利用少量的标注样本和大量的未标注样本进行训练和分类的问题，输入数据是已标记和未标记样例的混合。

S: 强化学习简介, <https://wenku.baidu.com/view/1eb6b251b636b64c2c35727a5e9856a561226c0.html?from=search> (后同)

智能信息网络 29

5.1.2 机器学习算法分类

监督学习

❖ 标定的训练数据，训练过程是根据目标输出与实际输出的误差信号来调节参数

无监督学习

- 不存在标定的训练数据，学习机根据外部数据的统计规律来调节系统参数，以使输出能反映数据的某种特性

半监督学习

- 结合（少量的）标定训练数据和（大量的）未标定数据来进行学习

智能信息网络 30

5.1.2 机器学习算法分类

强化学习

输入数据作为对模型的反馈，不像监督模型那样，输入数据仅仅是作为一个检查模型对错的方式，在强化学习下，输入数据直接反馈到模型，模型必须对此立刻作出调整。

强化学习智能体/环境接口建模

https://mp.weixin.qq.com/s/AaEoWrgj64YPa0KX9p_0g

智能信息网络 31


20260512

智能信息网络 32

5.1.2 机器学习算法分类

深度学习

深度学习通过一个人造的神经网络来学习，这一人造神经网络运转起来与人类大脑非常相似，深度神经网络包括一个输入层、一个输出层和多个隐含层。深度学习从数据中提取和学习特征。



输入层 隐含层 输出层

图像识别

智能信息网络 33

5.1.2 机器学习算法分类

分类与回归


监督学习

分类问题：在监督学习中，如果样本的**标签是整数**，则预测函数是一个向量到整数的映射，这类问题称为分类问题。

回归问题：在监督学习中，如果**标签值是连续实数**，则预测函数是向量到连续实数的映射，这类问题称为回归问题。

8: 雷明 机器学习与应用[M].北京:清华大学出版社,2019(后同).

智能信息网络 34



5.1.3 模型评价指标

性能度量

性能度量(performance measure)是衡量模型泛化能力的评价标准, 反映了任务需求。使用不同的性能度量往往会导致不同的评判结果。

什么样的模型是“好”的, 不仅取决于算法和数据, 还取决于任务需求

机器学习算法和模型的好坏, 需要定义衡量模型精度的指标, 常用指标有**精度与召回率**、**ROC曲线**、**混淆矩阵**以及**交叉验证**。

智能信息网络 37

5.1.3 模型评价指标

精度和召回率

测试样本:

正样本被分类器判定为正样本的数量记为**TP(True Positive)**,
 被判定为负样本数量记为**FN (False Negative)** .
 负样本被分类器正确判定为负样本的数量为**TN (True Negative)** ,
 被判定为正样本的数量记为**FP (False Positive)**

精度定义为:

$$\frac{TP}{TP + FP}$$

召回率定义为:

$$\frac{TP}{TP + FN}$$

混淆矩阵:

	判定为正	判定为负
正样本	TP	FN
负样本	FP	TN

样本分类树:

```

graph TD
    样本 --> 正样本
    样本 --> 负样本
    正样本 --> 正样本_TP[TP True Positive]
    正样本 --> 正样本_FN[FN False Negative]
    负样本 --> 负样本_FP[FP False Positive]
    负样本 --> 负样本_TN[TN True Negative]
  
```

智能信息网络 38

5.1.3 模型评价指标

ROC (Receiver Operating Characteristic受试者工作特征) 曲线

混淆矩阵:

	判定为正	判定为负
正样本	TP	FN
负样本	FP	TN

真阳率 (TPR) : 是所有正样本被分类器判定为正样本的比例(召回率)

$$TPR = \frac{TP}{TP + FN}$$

假阳率 (FPR) : 是所有负样本被分类器判定为正样本的比例

$$FPR = \frac{FP}{FP + TN}$$

分类阈值: 模型在预测时会给出一个概率值, 超过某个阈值则判定为正样本, 否则为负样本。ROC曲线通过改变这个阈值, 计算对应的TPR和FPR, 绘制出曲线。

AUC值 (Area Under Curve): AUC值是ROC曲线下方的面积, 范围在0到1之间。

其中AUC=0.5表示随机猜测, AUC=1表示完美分类。

二元分类器的ROC曲线示例

智能信息网络 39

ROC分析示例 (二分类)

分析网络入侵检测的数据(ROCdata.xlsx), 包含两列数据: 模型预测的概率值 (Predicted Probability) 和实际的标签 (Actual Label)。

实际标签中, 1代表攻击流量, 0代表正常流量。

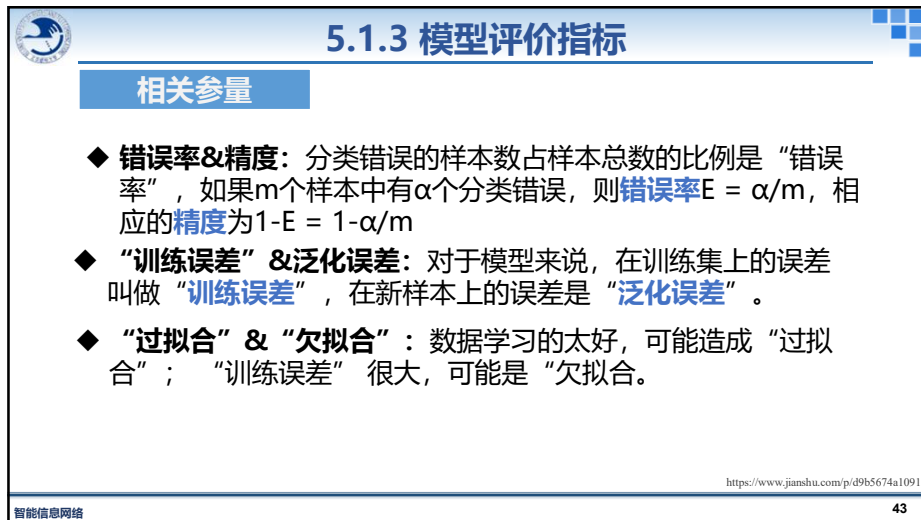


Predicted Probability	Actual Label
0.209744008	0
0.174117372	0
0.413007963	1
0.325705242	0
0.815115209	1
0.519847315	0
0.080472758	0

原始数据

ROC曲线

ROC curve (Overall AUC = 0.98)


智能信息网络 40



5.1.4 模型选择

模型选择

欠拟合产生原因：
模型本身过于简单，如数据本身是非线性的但使用了线性模型；特征数太少无法正确建立映射关系。



直观表现
训练得到的模型在训练集上表现差，没有学到数据的规律

智能信息网络 45

5.1.4 模型选择

模型选择

过拟合产生原因：
(1) 模型本身过于复杂，需要选用较为简单的模型；
(2) 训练样本太少或者缺少代表性，需要增加样本数及多样性；
(3) 训练样本噪声的干扰，需要剔除噪声数据或者改用对噪声不敏感模型。




直观表现
在训练集上表现好，但在测试集上表现不好，推广泛化性能差

智能信息网络 46

5.1.4 模型选择

示例



右图中的四次多项式对图中所有的点完成了拟合，但却并没有抽象出一般规律

右图为了完成两个异常点的分割，导致边界过于复杂，也失去了泛化能力

智能信息网络 47

5.1 单元小结

- 1、掌握人工智能与机器学习的基本概念
- 2、了解机器学习模型不同的分类方法

人工智能与机器学习



智能信息网络 48

5.2 网络中机器学习典型算法

主要内容

5.2.1 监督学习-贝叶斯分类

5.2.2 监督学习-支持向量机

5.2.3 监督学习-决策树

5.2.4 深度学习-卷积神经网络


5.2.5 强化学习-Q学习



智能信息网络 49

5.2.1 监督学习-贝叶斯分类

贝叶斯定理



托马斯·贝叶斯 (Thomas Bayes)



已知信息 → 未知信息

正向概率



未知信息 ← 已知信息

逆向概率

贝叶斯定理是解决“逆概率”问题

5: 有预测能力的人, 都会用贝叶斯来思考 https://mp.weixin.qq.com/s/Zm-WqIPbMvduw8i6_w1gKg

智能信息网络 50

5.2.1 监督学习-贝叶斯分类

贝叶斯定理

后验概率

↓

$P(A|B)$

先验概率

后验概率

↓

$P(A) \frac{P(B|A)}{P(B)}$

可能性函数

求 $P(A|B)$: 网络中某个B事件发生情况下, 故障A事件的发生概率

- ◆ B发生之前, 对A的发生有一个基本的概率判断, 称为A的先验概率, 用 $P(A)$ 表示
- ◆ B发生之后, 对A的发生概率重新评估, 称为A的后验概率, 用 $P(A|B)$ 表示
- ◆ 同理: $P(B)$ 和 $P(B|A)$

$P(A)$ 为A的先验概率 (边缘概率), $P(B)$ 为B的先验概率 (边缘概率)
 $P(A|B)$ 是A的后验概率 (条件概率), $P(B|A)$ 是B的后验概率 (条件概率)
 A与B的联合概率表示为 $P(A,B)$, $P(A,B)=P(A|B) \times P(B)$, $P(A,B)=P(B|A) \times P(A)$

智能信息网络 51

5.2.1 监督学习-贝叶斯分类

贝叶斯定理

后验概率

↓

$P(A|B)$

先验概率

后验概率

↓

$P(A) \frac{P(B|A)}{P(B)}$

可能性函数

求 $P(A|B)$: 网络中某个B事件发生情况下, 故障A事件的发生概率

可能性函数: 调整因子, 由新事件发生后带来的调整, 使得后验概率更接近真实概率

后验概率 = 先验概率 × 可能性函数 (调整因子)

$P(A)$ 为A的先验概率 (边缘概率), $P(B)$ 为B的先验概率 (边缘概率)
 $P(A|B)$ 是A的后验概率 (条件概率), $P(B|A)$ 是B的后验概率 (条件概率)
 A与B的联合概率表示为 $P(A,B)$, $P(A,B)=P(A|B) \times P(B)$, $P(A,B)=P(B|A) \times P(A)$

智能信息网络 52

5.2.1 监督学习-贝叶斯分类

贝叶斯定理

全概率公式计算

$$P(A) = P(A|B)P(B) + P(A|B')P(B')$$

如果B和B'构成一个问题的全部（全部的样本空间），那么事件A的概率，就等于B和B'的概率分别乘以A对这两个事件的条件概率之和。

5.2.1 监督学习-贝叶斯分类

贝叶斯分类

在分类问题中，设随机变量A是要被决策的类，B是属性向量集。

如给定一个测试数据项的属性向量为 B_0 ，需要计算类概率 $P(A, B_0)$ ，即求出对应于A的概率最大值（以 B_0 为特征的测试数据的类）

$$P(A|B) = P(A) \frac{P(B|A)}{P(B)}$$

后验概率
后验概率
可能性函数

先验概率

属性向量 $B = \{B_1, B_2, \dots, B_k\}$

随机变量 $A = \{A_1, A_2, \dots, A_l\}$ (l 个类)


朴素贝叶斯分类器：属性相对独立

贝叶斯网络：属性非独立

5.2.1 监督学习-贝叶斯分类

贝叶斯网络

贝叶斯网络(Bayesian network)，是一种模拟人类推理过程中因果关系的不确定性处理模型，其网络拓扑结构是一个有向无环图(DAG)。



贝叶斯网络是在贝叶斯定理的基础上，针对因果关系的不确定性的问题，求事件联合概率和边缘概率。联合概率解答多个事情共同发生的可能，边缘概率解释某个结点发生的概率

5.2.1 监督学习-贝叶斯分类

贝叶斯网络

贝叶斯网络4种推理模式：

- (1) **诊断推理**，从影响结果(证据)推理出原因，也称为后向推理。
- (2) **因果推理**，从原因推理出影响结果，也成为前向推理。给定原因，求解最有可能产生的影响。
- (3) **交互因果**，推理多个原因共同产生一个影响结果。给定影响结果和其中一个原因，推理出另一个原因的概。
- (4) **混合推理**，以上3种推理模式的混合。

案例分析：采用朴素贝叶斯算法对网络状态进行分类

问题描述

构建一个通信网络故障诊断系统，目的是根据网络设备的某些特征来分类网络状态

特征变量：

- 带宽使用率 (Bandwidth Usage %):
 - 数据服从正态分布，均值为 60，标准差为 15，范围在 0 到 100 之间。
- 丢包率 (Packet Loss %):
 - 数据服从均匀分布，范围在 0 到 0.01 之间。
- 网络延迟 (Latency ms):
 - 数据服从正态分布，均值为 50，标准差为 10，范围在 0 到 100 之间。
- 信号强度 (Signal Strength):
 - 数据服从均匀分布，范围在 0 到 100 之间。
- 设备类型 (Device Type):
 - 数据为整数，范围在 0 到 2 之间，分别表示路由器、交换机和无线接入点。

目标变量 (Network Status):

- 网络状态分为 "Normal" 和 "Abnormal" 两类。
- 判定为 "Abnormal" 的条件为：
 - 带宽使用率 > 90%
 - 丢包率 > 0.005%
 - 网络延迟 > 70 ms
 - 信号强度 < 30
- 如果满足上述任意一个条件，则网络状态为 "Abnormal"，否则为 "Normal"。

数据处理与保存：

- 数据生成后，被打乱顺序以确随机性。
- 最终数据保存到 Excel 文件 CommunicationNetworkData_Balanced.xlsx 的 "原始数据" 工作表中。

数据加载与预处理：

- 从 Excel 文件中加载数据，并对分类变量进行编码，使其适合模型训练。

数据分割：

- 将数据集分割为训练集和测试集，通常使用 80% 的数据作为训练集，20% 作为测试集。

模型训练：

- 使用训练集数据训练朴素贝叶斯分类器。

模型预测：

- 对测试集进行预测，并评估模型的性能，如准确率、精确率、召回率和 F1 分数。

结果保存：

- 将训练集和测试集分别保存到 Excel 文件的不同工作表中，并在测试集中记录原始和预测的目标变量。

57

5.2.1 监督学习-贝叶斯分类

应用思考：网络故障的智能溯源？

案例教学

当上层某些传输系统出现故障告警时，计算出底层哪个光缆段出现线路故障的概率最大（故障溯源）？

某DWDM光网络（设有4个传输段）中的局部业务通路组织

58

5.2.1 单元小结

- 掌握贝叶斯的基本原理
- 了解贝叶斯分类法在信息网络中的应用

贝叶斯分类法可用于网络的故障溯源

59

5.2.2 监督学习-支持向量机：SVM

a

b

c

60

5.2.2 监督学习-支持向量机

定义

支持向量机 (Support Vector Machine, SVM)

- ◆ 什么是支持向量 (Support Vector) :
 - ◆ 支持或支撑平面上把两类类别划分开来的超平面的向量点
- ◆ “机 (machine, 机器)”
 - ◆ 一个算法。在机器学习领域，常把一些算法看做是一个机器，如分类机（也叫分类器）
- ◆ 支持向量机本身是一种监督式学习的方法，广泛应用于统计分类以及回归分析中


S: 雷明 机器学习与应用[M]. 北京: 清华大学出版社, 2019 (后同)

智能信息网络 61

5.2.2 监督学习-支持向量机

定义


- 目标:
 - 找到一个超平面，使得它能够尽可能多的将两类数据点正确的分开，同时使分开的两类数据点距离分类面最远
- 解决方法:
 - 构造一个在约束条件下的优化问题，具体的说是一个约束二次规划问题，求解该问题，得到分类器



智能信息网络 62

5.2.2 监督学习-支持向量机

线性分类器



数据:
学生的数学成绩(横轴)
统计学成绩(纵轴)
在“机器学习 (ML)”课程上的表现
(使用“好”和“差”两个标签描述)

如何判定数学、统计学分数和ML课程表现之间的关系?


<https://mp.weixin.qq.com/s/nE17019xorTTEOwgQjblA> (后同)

智能信息网络 63

5.2.2 监督学习-支持向量机

线性分类器

思路：基于某种“算法”，接受学生的数学和统计学分数输入，预测学生在图中是红点还是绿点（绿/红也称为分类或标签）。




智能信息网络 64

5.2.2 监督学习-支持向量机

线性分类器

最大化分类间隔就是支持向量机的基本思想

- ◆ 训练样本的线性分类器不唯一
- ◆ 找到正确分类训练数据的一组直线
- ◆ 在找到的所有直线中，选择那条离最近的数据点距离最远的直线




线性分类器是n维空间中的分类超平面，将空间切分成两部分。对于二维空间，是一条直线；对于三维空间，是一个平面；超平面是在更高维空间的推广。

智能信息网络 65

5.2.2 监督学习-支持向量机

支持向量定义




支持向量 (support vector) :
距离最近的数据点。

间隔 (margin) :
支持向量定义的沿着分隔线的区域。

智能信息网络 66

5.2.2 监督学习-支持向量机

支持向量机




假设训练数据集包含 n 个数据点，其中每个数据点用一个元组表示 (x_i, y_i) ，其中 x_i 为表示数据点的向量， y_i 为数据点的分类/标签（令 y_i 的取值为-1或1）。那么，分割超平面就可以表示为： $w \cdot x - b = 0$ 。

其中， w 为超平面的法向量。

智能信息网络 67

5.2.2 监督学习-支持向量机

支持向量机



将某一数据点 x_i 代入 $w \cdot x - b$ 后，根据所得结果的正负，就可以判断数据点的分类。

相应地，确定间隔的两个超平面则可以表示为 $w \cdot x - b = 1$ 、 $w \cdot x - b = -1$

这两个超平面之间的距离，也就是间隔的宽度为 $2/\|w\|$ 。

智能信息网络 68

5.2.2 监督学习-支持向量机

支持向量机

SVM的目标是在正确分类的前提下，最大化间隔宽度。

在满足 $y_i(wx_i - b) \geq 1$ 的前提下，间隔最大等价于：

$$\max \frac{2}{\|w\|}, \text{ s.t. } y_i(wx_i - b) \geq 1$$

问题转化

$$\min \frac{\|w\|^2}{2}, \text{ s.t. } y_i(wx_i - b) \geq 1$$

具体公式推导过程参考书，
雷明. 机器学习与应用[M].
北京：清华大学出版社，
2019.

智能信息网络 69

5.2.2 监督学习-支持向量机

线性不可分问题

- 若对于训练样本线性不可分怎么办？
- 如何找到正确的分类曲线和正确的超平面对线性不可分样本进行分类

线性不可分情况 拓展为高维线性可分

智能信息网络 70

5.2.2 监督学习-支持向量机

线性不可分问题

- 若将原样本变换到更高维的特征空间，使得原样本变为线性可分
- 将特征向量 X 转化为 $\phi(X)$ ，使其转化为线性可分情况

Input space Feature space

智能信息网络 71

5.2.2 监督学习-支持向量机

非线性分类器


Accuracy: 75%

将数据投影到一个线性可分的空间，然后在那个空间寻找超平面！

智能信息网络 72

5.2.2 监督学习-支持向量机

非线性分类器



将上页图中的数据投影到一个三维空间：然后运行SVM


$$\begin{aligned} X_1 &= x_1^2 \\ X_2 &= x_2^2 \\ X_3 &= \sqrt{2}x_1x_2 \end{aligned}$$

投影坐标

智能信息网络 73

5.2.2 监督学习-支持向量机

非线性分类器




- ◆ 训练集上精确度可达100%
- ◆ 没有过于接近数据
- ◆ 原空间的分割边界的形状由投影决定
- ◆ 在投影空间中，分割边界总是一个超平面
- ◆ 投影数据的主要目标是为了利用SVM寻找超平面的强大能力
- ◆ 映射回原始空间后，分割边界不再是线性

智能信息网络 74

5.2.2 监督学习-支持向量机

非线性分类器

- ◆ 问题1：如何知道应该把数据投影到哪个空间？
- ◆ 问题2：是先投影数据接着运行SVM？



智能信息网络 75

5.2.2 监督学习-支持向量机

非线性分类器

- ◆ SVM在线性可分的数据上效果极为出色
- ◆ 线性不可分的数据可以投影至完美线性可分或基本线性可分的空间，从而将问题转化

让SVM得到普遍应用的关键是投影到高维

如何投影???

智能信息网络 76

5.2.2 监督学习-支持向量机

■ 例1: 原样本的分类边界为 $ax_1^2 + bx_2^2 = 1$, 现将其二维样本转换为三维:
 $[x_1, x_2] \rightarrow [z_1, z_2, z_3] = [x_1^2, 2x_1x_2, x_2^2]$
 变换后, 原样本可用一个超平面 $w_1z_1 + w_2z_2 + w_3z_3 + c = 0$ 作为分类边界。

$\Phi: \mathbb{R}^2 \rightarrow \mathbb{R}^3$
 $(x_1, x_2) \mapsto (z_1, z_2, z_3) := (x_1^2, \sqrt{2}x_1x_2, x_2^2)$

77

5.2.2 监督学习——SVM支持向量机

● 鸢尾花数据集 (Iris Dataset)

- 简介: 这是一个经典的分类数据集, 非常适合教学使用。它包含了 150 个样本, 分为 3 个类别 (山鸢尾、变色鸢尾、维吉尼亚鸢尾), 每个类别有 50 个样本。每个样本有 4 个特征, 分别是花萼长度、花萼宽度、花瓣长度和花瓣宽度。
- 使用场景: 可以使用决策树算法根据这 4 个特征对鸢尾花的类别进行分类预测。

sepal length (cm) 萼片长度	sepal width (cm) 萼片宽度	petal length (cm) 花瓣长度	petal width (cm) 花瓣宽度	Target 目标类别
5.1	3.5	1.4	0.2	0
5.7	2.8	4.5	1.3	1
6.9	3.2	5.7	2.3	2

78

5.2.2 监督学习——SVM支持向量机: 鸢尾花

加载和准备数据

- 加载Iris数据集: 使用sklearn.datasets.load_iris()加载数据。
- 选择特征: 选择前两个特征 (萼片长度和宽度) 用于二维可视化。

数据预处理

- 划分训练集和测试集: 使用train_test_split将数据划分为训练集 (80%) 和测试集 (20%)。
- 标准化数据: 使用StandardScaler对数据进行标准化, 确保特征具有零均值和单位方差。

训练SVM模型

- 初始化SVM模型: 使用SVC类, 选择线性核函数, 设置正则化参数C=1.0和随机种子42。
- 拟合模型: 使用训练数据训练SVM模型。

模型评估

- 预测测试集: 对测试集进行预测。
- 计算准确率: 使用accuracy_score评估模型的预测准确率。

可视化结果

- 生成网格点: 创建特征空间的网格点用于绘制决策边界。
- 预测网格点类别: 对网格点进行标准化并预测类别。
- 绘制决策边界: 使用contourf绘制决策边界, scatter绘制训练集和测试集的样本点。
- 设置图形属性: 添加标签、标题, 并显示图形。

预测准确率: 0.9

79

5.2.2 监督学习-支持向量机

应用思考: 不同特征的网络传输信号智能识别?

案例教学

基于高阶累积量和双谱包络峰值提取特征值E。
 利用分类算法可对不同特征值的信号进行识别。

数字调制信号

分类器 I

$T1 = (E1(i), E2(i))$

MPSK, MQAM, MFSK

WPM, OFDM, MASK

分类器 II

$T2 = (E2(i), E3(i))$

MASK

WPM, OFDM

分类器 III

$T3 = (E3(i), E4(i))$

WPM

OFDM

80

5.2.2 单元小结

1. 掌握支持向量机的基本原理
2. 了解支持向量机方法在信息网络中的应用

支持向量机方法可用于网络中信号识别



智能信息网络

81

5.2.3 监督学习-决策树

决策树

互联网中各种应用类型的流量都有其统计特征, 通过分析这些特征可以区分其应用类型, 可合理规划网络资源及安全管理。

流量分类的2种方法

基于端口号分类

- 策略: 使用传输层协议UDP或TCP端口号进行分类
- 优势: 易于实现, 而且算法时间复杂度低
- 劣势: 随着应用程序及协议的多元化以及端口跳变和端口伪装技术的出现, 基于端口识别的流量分类方法的准确度越来越低, 该方法不再可靠

机器学习算法

- 策略: 收集历史流量数据, 将朴素贝叶斯、最近邻、**决策树**和支持向量机等最常用的机器学习算法用于流量分类技术
- 优势: 预测准确度较高
- 劣势: 需要大量计算资源长时间训练

S: [1]于孝美, 陈贞刚, 彭立志. 基于决策树的网络流量分类方法[J]. 济南大学学报(自然科学版), 2012(03):74-78. [2]雷明. 机器学习与应用[M]. 北京: 清华大学出版社, 2019(后同)

智能信息网络

82

5.2.3 监督学习-决策树

决策树优缺点


优点	局限
◆ 易于理解, 可视化分析, 容易提取出规则	◆ 容易发生过拟合
◆ 可以同时处理多类型数据	◆ 容易忽略数据集中属性的相互关联
◆ 适合处理有缺失属性的样本	◆ 分类结果不唯一, 受属性选择影响
◆ 能够处理不相关的特征	◆ 结果偏向数值比较多的特征
◆ 运行速度比较快	

智能信息网络

83

5.2.3 监督学习-决策树

基本定义



- ◆ 根节点: 包含样本的全集
- ◆ 内部节点: 对应特征属性的测试
- ◆ 叶子节点: 代表决策的结果

决策树是一种基于规则的方法, 重点是一种解决分类问题的算法。在树的每个决策点处, 根据判断结果进入一个分支, 反复执行这种操作直到到达叶子节点, 得到预测结果。这些规则是通过训练得到的, 而不是人工定制的。

S: 雷明. 机器学习与应用[M]. 北京: 清华大学出版社, 2019(后同)

智能信息网络

84

5.2.3 监督学习-决策树

决策树的生成

- ◆ 在特征向量中的多个分量中，每个决策点上应该选择哪个分量做判定？
- ◆ 选定一个特征后，判定的规则是什么？
- ◆ 何时停止分裂，把节点设置为叶子节点？
- ◆ 如何为每个叶子节点赋予类别标签或者回归值？

特征选择 → 决策树生成 → 决策树剪枝

智能信息网络 85

5.2.3 监督学习-决策树

典型决策树算法

决策树算法 {

- ID3 利用信息增益来进行特征选择的决策树学习过程
- C4.5 信息增益率
- CART 利用基尼系数取代信息熵模型

信息熵：描述样本属性的不确定性

信息增益：某一属性信息熵的增量，可作为判断是否用该属性划分数据集的标准

信息增益率：信息增益/该特征的信息熵，用于解决信息增益对属性选择取值较多的问题

https://blog.csdn.net/roguesir/article/details/76619919?utm_term=.E4%BF%A1%E6%81%AF%E5%A2%9E%E7%9B%8A%E7%8E%87%E6%98%AF%E4%B8%B0%E4%B9%88&utm_medium=distribute.pc_aggpage_search_result.none-task-blog-2-all-sbaiduweb-default-7-76619919&spm=3001.4430

智能信息网络 86

5.2.3 监督学习-决策树

C4.5 决策树算法

案例教学

C4.5算法：

- (1) 对每个离散的流属性计算其信息增益率，对于非离散的属性要先进行离散化处理；
- (2) 选出具有最大信息增益率的属性做为分裂属性，对给定样本集合S进行划分，并创建一个节点以该属性标记根据属性值的不同创建分支，由此来划分样本。
- (3) 用同样的方法，再对每个子集进行划分，依次递归下去，每个分支上可形成各自的样本判定树，最终形成一颗规则判定树。
- (4) 为达到最优状态，去除异常分支，还需要进行剪枝处理。

智能信息网络 87

5.2.3 监督学习-决策树

C4.5 算法流程

C4.5 决策树生成

输入训练集数据 → 数据预处理 → 生成规则树 → 输出规则树 → 读入测试集数据 → 测试数据 → 计算分类精度 → 输出测试结果及精度

分类精度

$$P_{c_i} = \frac{T_{tp}}{(T_{tp} + F_{fp})}$$

正确分类的流量数目

错误分类的流量数目

智能信息网络 88

5.2.3 监督学习-决策树

鸢尾花数据集 (Iris Dataset)

- 简介：这是一个经典的分类数据集，非常适合教学使用。它包含了 150 个样本，分为 3 个类别（山鸢尾、变色鸢尾、维吉尼亚鸢尾），每个类别有 50 个样本。每个样本有 4 个特征，分别是花萼长度、花萼宽度、花瓣长度和花瓣宽度。
- 使用场景：可以使用决策树算法根据这 4 个特征对鸢尾花的类别进行分类预测。

sepal length (cm) 萼片长度	sepal width (cm) 萼片宽度	petal length (cm) 花瓣长度	petal width (cm) 花瓣宽度	Target 目标类别
5.1	3.5	1.4	0.2	0
5.7	2.8	4.5	1.3	1
6.9	3.2	5.7	2.3	2

山鸢尾 setosa
变色鸢尾 versicolor
维吉尼亚鸢尾 virginica

智能信息网络 89

5.2.3 监督学习-决策树

鸢尾花数据集：决策树决策过程如下：

特征选择：

- 在构建决策树时，首先要选择一个特征作为根节点的测试条件。例如，在鸢尾花数据集中，有花萼长度、花萼宽度、花瓣长度和花瓣宽度四个特征。算法会根据某种准则（如信息增益、基尼不纯度等）选择一个最优的特征进行划分。以信息增益为例，信息增益衡量的是划分前后数据集的信息熵的变化，信息增益越大，说明该特征对分类的贡献越大。

数据集划分：

- 根据选择的特征和其取值，将数据集划分成不同的子集。假设选择了花瓣长度作为根节点的特征，并且设定一个阈值（如 2.5），那么数据会被分为两部分：花瓣长度小于 2.5 的数据和花瓣长度大于等于 2.5 的数据。

递归构建子树：

- 对每个子集重复上述特征选择和数据集划分的过程，直到满足某个停止条件。停止条件可以是子集中的数据都属于同一类别，或者达到了预设的树的最大深度等。

决策预测：

- 在预测时，对于一个新的数据样本，从根节点开始，根据该样本在相应特征上的取值，沿着决策树的路径向下游移动，直到到达一个叶节点，该叶节点对应的类别就是预测结果。

sepal length (cm) 萼片长度	sepal width (cm) 萼片宽度	petal length (cm) 花瓣长度	petal width (cm) 花瓣宽度	Target 目标类别
5.1	3.5	1.4	0.2	0
5.7	2.8	4.5	1.3	1
6.9	3.2	5.7	2.3	2

模型准确率: 1.0
分类报告:

	precision	recall	f1-score	support
0	1.0	1.0	1.0	19.0
1	1.0	1.0	1.0	13.0
2	1.0	1.0	1.0	13.0
accuracy	1.0	1.0	1.0	1.0
macro avg	1.0	1.0	1.0	45.0
weighted avg	1.0	1.0	1.0	45.0

智能信息网络 90

5.2.3 监督学习-决策树

决策树案例

来自同一数据集的4000条数据（含四种类型，每种类型有多个属性），包括3600条带分类的数据（含P2P, FTP-data, MAIL, WWW 四种类型）和400条无分类的数据，需要利用已分类的3600条数据来训练决策树模型，并利用已经训练好的决策树模型对未分类的400条数据进行分类

3600条已分类数据

流量类别
P2P
FTP-data
MAIL
WWW

流量数目

智能信息网络 91

5.2.3 监督学习-决策树

某**输出结果的分析及改进

重合部分表示分类结果和真实分类一致，即完成了正确分类

通过单精度精确度分析可知www类型分类效果较差，且www被错误的分为database类型较多

改进方向应该是将www类型的离散化区间进一步细分，和其它类型的离散化区间区别开，提高www类型的分类精度

模型评估

- 整体部分分类精度: 77.75%
- www类型的分类精度: 72.05%
- mail类型的分类精度: 81.25%
- database类型的分类精度: 91.18%
- p2p类型的分类精度: 80.24%

智能信息网络

5.2.3 监督学习-决策树

应用思考：网络数据的智能分类？

大量数据业务引起的网络拥塞现象严重，如何提高服务质量避免网络时延和拥塞，确保业务流量通畅？

通过流量分类（www, mail,...）技术实现QoS调度，以更好实现现有网络的扩容改造。必须对网络流量中各种应用进行准确的分类与识别



智能信息网络 93

5.2.3 小结

- 1、掌握决策树的基本原理
- 2、了解决策树在网络中的应用


决策树可用于网络流量分类




智能信息网络 94

5.2.4 深度学习-神经网络

深度学习是机器学习的分支，使用的模型是人工神经网络



神经元——>神经层——>神经网络




人工神经网络 (ANN) 架构

<https://mp.weixin.qq.com/s/HjBbfY9XuvMgeddEkZEA> (后同)

智能信息网络 95

5.2.4 深度学习-神经网络


神经元模型



- 生物神经元的启发：
 - 神经网络的灵感来源于人脑中的神经元。每个神经元接收输入信号，经过处理后产生输出信号。
 - 树突**：一个神经元可以有多个树突，负责接收来自其他神经元的信号，并将这些信号传递到胞体。
 - 细胞核**：维持神经元细胞的正常代谢活动，并处理来自树突的信息。
 - 轴突与轴突末端**：负责将电信号传导到其他神经元。扩展出多个轴突末梢，每个轴突末梢负责将信号传递给下一个神经元。
 - 突触间隙**：神经元之间的连接区域。
- 人工神经元（感知器）：
 - 由输入、权重、偏置和激活函数组成。
 - 输入**：来自其他神经元或外部数据。
 - 权重**：表示输入的重要性，通过训练调整。
 - 偏置**：类似于截距，帮助模型更好地拟合数据。
 - 激活函数**：将线性组合转换为非线性输出，常见的有sigmoid、ReLU、tanh等。

智能信息网络 96

5.2.4 深度学习-神经网络




逻辑回归的工作原理：
先对特征进行线性加权，然后通过激活函数进一步处理（非线性变化）。

特征线性叠加 (w_k 为权重, b 为偏置截距)

$$z = x_1 w_1 + \dots + x_k w_k + \dots + x_K w_K + b$$

激活函数的非线性变换

Sigmoid 函数 (S函数)

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$


神经网络的训练过程本质上是寻找最优权重矩阵和偏置的过程。

智能信息网络 97

5.2.4 深度学习-神经网络

常用的激活函数

梯度消失问题

适合用于二分类问题的输出层

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

有助于零中心化, 加速训练

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

tanh

$$\tanh(x)$$

ReLU

$$\max(0, x)$$

Leaky ReLU

$$\max(0.1x, x)$$

Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

在输入为负时, 输出为 αx , 而非 0, 避免了神经元“死亡”, 保持了 ReLU 在正区间的优势, 同时改进了负区间的梯度问题。

保留较大特征、减少输出维度
计算量大、灵活性降低、资源需求高

在输入为负时, 输出等于输入, 梯度为 1。
在输入为负时, 输出为 $\alpha(e^x - 1)$, 能够提供平滑的梯度, 避免梯度消失。
输出范围接近零中心化, 有助于加速训练。

智能信息网络 98

5.2.4 深度学习-神经网络

神经网络


- 人工神经网络 (ANN)
- 全连接神经网络 (FNN)
- 深度神经网络 (DNN)
- 卷积神经网络 (CNN)
- 循环神经网络 (RNN)
- 长短期记忆 (LSTM)
-

- 全连接神经网络 FNN 的节点很多, 面临非常大的数据量, 因此引入卷积神经网络 CNN, 可以降低网络模型的复杂度
- 全连接神经网络 FNN 没有体现时间维度, 因此引入循环神经网络 RNN, 可以解决时序性问题
- 循环神经网络 RNN 难以处理长期记忆问题, 因此引入长短期记忆 (LSTM) 网络
-

智能信息网络 99

5.2.4 深度学习-神经网络

全连接神经网络



- 基本结构: 输入层、隐藏层、输出层
- 输入层: 向神经网络的输入数据特征
- 隐藏层: 处理数据, 提取特征。可以有多个隐藏层, 形成深度网络。提升神经网络的拟合能力
- 输出层: 输出神经网络的预测或分类结果

全连接: 是每一个结点都与上一层的所有结点(神经元)相连, 用来把前边提取到的特征综合起来, 最后输出。

前向传播(预测过程): 将当前节点的所有输入执行当前节点的计算, 作为当前节点的输出节点的输入。

$$a_4 = f_1(x_1 w_{41} + x_2 w_{42} + x_3 w_{43} + b_4) \quad y_1 = f_2(a_4 w_{84} + a_5 w_{85} + a_6 w_{86} + a_7 w_{87} + b_8)$$

反向传播(训练过程): 将当前节点的输出节点对当前节点的梯度损失, 乘以当前节点对输入节点的偏导数, 作为当前节点的输入节点的梯度损失。

$$\frac{\partial \xi}{\partial w} = \frac{\partial \xi}{\partial f} \cdot \frac{\partial f}{\partial w} \quad \frac{\partial \xi}{\partial b} = \frac{\partial \xi}{\partial f} \cdot \frac{\partial f}{\partial b} \quad w = w - \alpha \frac{\partial \xi}{\partial w} \quad b = b - \alpha \frac{\partial \xi}{\partial b}$$

智能信息网络 100

5.2.4 深度学习-神经网络

深度神经网络

输入层 隐藏层 输出层

网络越深, 变换维度越高, 拟合能力越强。

缺点: 容易过拟合!

具有多个隐藏层, 第N层的神经元与第N-1层的所有神经元连接

本质上是一个拟合函数, 每向前传递一层, 就对输入进行一次变换

智能信息网络 101

一个教学例子网站

• <https://playground.tensorflow.org/>

智能信息网络 102

5.2.4 深度学习-神经网络

前向传播

例如:
 $0.98 = \text{sigmoid}(4 = 1 \cdot 1 + (-1) \cdot (-2) + 1)$
 0.12 的计算类似

激励函数

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

智能信息网络 103

5.2.4 深度学习-神经网络

前向传播

输入向量 $f\left(\begin{bmatrix} 1 \\ -1 \end{bmatrix}\right) = \begin{bmatrix} 0.62 \\ 0.83 \end{bmatrix}$ 输出向量

给定网络结构, 定义一个函数集

智能信息网络 104

5.2.4 深度学习-神经网络

矩阵运算

$$\sigma\left(\begin{bmatrix} 1 & -2 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 0.98 \\ 0.12 \end{bmatrix}$$

智能信息网络 105

5.2.4 深度学习-神经网络

误差评估

训练数据 $[X, \hat{y}]$

输入特征 $x_1, x_2, \dots, x_n$

给定一组参数

激活函数

输出结果 y

真实结果 $\hat{y}$

MSE

损失函数: 用于衡量模型预测与真实值之间的差异

均方误差MSE: $L(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2$

全连接神经网络

- X 表示输入的训练数据特征
- $\hat{y}$ 表示训练数据特征对应的真实数据 (标签)
- y 表示通过神经网络计算得到的输出结果 (包括线性加权求和以及激活函数处理)
- 损失函数可通过MSE计算, 衡量 y 和 $\hat{y}$ 之间的差距
- 训练过程中通过不断调参和优化, 减少损失函数

关键问题:

- (1) 参数数量大, 训练困难
- (2) 未体现时间维度关联性

智能信息网络 106

5.2.4 深度学习-神经网络

训练数据 $[X, y]$

输入特征 $x_1, x_2, \dots, x_n$

激活函数

输出结果 y

真实结果 $\hat{y}$

MSE

- 1) 前向传播:
 - 网络接受样本输入, 通过逐层计算得到最终的预测结果;
- 2) 计算误差:
 - 将网络输出与期望比较, 计算网络误差和损失 L ;
- 3) 误差反向传播:
 - 从输出层开始, 根据链式法则, 逐层计算每个神经元的误差贡献 (即: 偏导);
- 4) 阐述更新:
 - 根据神经元误差贡献计算网络参数的梯度, 使用梯度下降法更新网络全部参数 (w 和 b), 使得下一次前向传播结果更加趋近于期望输出。
- 5) 重复以上过程
 - 直到网络的输出误差达到可接受的范围或达到预定的训练轮数。

传声筒 第四轮 王牌家族队

智能信息网络 107

5.2.4 深度学习-神经网络

针对上述问题 (1): 由于全连接神经网络节点很多, 面临非常大的数据量处理。通过引入卷积神经网络CNN, 可以去掉大量不重要参数, 降低神经网络模型的复杂度

卷积神经网络CNN

卷积核/滤波器

卷积过程

池化层

提取并汇集重要特征 有效降低模型复杂度

https://mp.weixin.qq.com/s/t8jq_bpEcQJmglqKarefQ (后同)

https://www.sohu.com/a/223277977_129720 (后同)

智能信息网络 108

5.2.4 深度学习-神经网络

卷积神经网络--卷积层

示例：5*5 的单色图像

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved Feature

- ◆ 用一个由 0 和 1 组成的 3*3 矩阵（滤波器）去和图像中的子区域做内积，每次迭代移动一个像素，这样该乘法会得到一个新的 3*3 的矩阵。
- ◆ 滤波器的任务是提取图像特征（根据需要采用多个滤波器来提取多个特征），它使用“优化算法”来决定 3*3 矩阵（滤波器）中具体的 0 和 1。
- ◆ 3*3 矩阵的每一个单个步骤被称作“步幅”，是卷积神经网络最重要的一个层次。
- ◆ 卷积层的两个关键操作：
 - 局部关联：每个神经元看做一个滤波器
 - 窗口滑动：滤波器对局部数据进行计算

https://mp.weixin.qq.com/s/7Pcfqbf_AvO4Odo1nOA_Q; <http://cs231n.github.io/convolutional-networks/>; https://www.sohu.com/a/223277977_129720 (后同)

智能信息网络 109

5.2.4 深度学习-神经网络

Input Volume (+pad 1) (7x7x3) Filter W0 (3x3x3) Filter W1 (3x3x3) Output Volume (3x3x2)

步幅：2

拓展：
蓝矩阵是输入图像（7x7x3），粉矩阵是卷积层的神经元，这里表示有两个神经元（w0,w1），提取两个特征。绿矩阵就是经过卷积运算后的输出矩阵

蓝矩阵(输入图像)与粉矩阵进行矩阵内积计算并将三个内积运算的结果与偏置值b相加, b=1,0

示例：如图中计算
第一个蓝矩阵与第一个粉矩阵内积计算为：-3
第二个蓝矩阵与第二个粉矩阵内积计算为：3
第三个蓝矩阵与第三个粉矩阵内积计算为：0

计算：-3+3+0+1=1 以此类推，得到绿矩阵

智能信息网络 110

5.2.4 深度学习-神经网络

卷积神经网络—池化层

- 池化层主要的作用是下采样，通过去掉不重要的样本，进一步减少参数数量—降维。
- 池化的方法很多，最常用的是最大池化。最大池化实际上就是在n*n的样本中取最大值，作为采样后的样本值。

最大池化

Single depth slice

1	1	2	4
5	6	7	8
3	2	1	0
1	2	3	4

max pool with 2x2 filters and stride 2

6	8
3	4

智能信息网络 111

5.2.4 深度学习-神经网络

卷积神经网络的训练过程

第二个阶段：当前向传播得出的结果与预期不相符时，将误差从高层次向低层次进行传播训练的阶段，即反向传播阶段。

第一个阶段：数据由低层次向高层次传播的阶段，即前向传播阶段。

```

graph TD
    A[初始化] --> B[给定输入向量和目标输出]
    B --> C[求隐层，输出层各单元的输]
    C --> D[求目标值和实际输出偏差e]
    D --> E{是否在容许误差内?}
    E -- 否 --> F[计算网络层中神经元的误差]
    F --> G[求误差梯度]
    G --> H[更新权重]
    H --> B
    E -- 是 --> I[训练结束，固定权重和阈值]
  
```

智能信息网络 112

5.2.4 深度学习-神经网络

卷积神经网络的特点

优点

- 共享卷积核，对高维数据处理无压力
- 无需手动选取特征，训练好权重，即得特征分类效果好

缺点

- 需要调参，需要大样本量，训练最好要GPU
- 物理含义不明确（并不知道每个卷积层到底提取到的是什么特征，而且神经网络本身就是一种难以解释的“黑箱模型”）

113

5.2.4 深度学习-神经网络

针对上述问题（2）：由于全连接神经网络未体现时间维度关联性，引入循环神经网络RNN，可以处理时序性问题

全连接神经网络

循环神经网络 (RNN)

- 1、收集所需的流量数据。
- 2、在不同时间传递神经元状态。
- 3、更新网络状态及调整参数。
- 4、重复直到获取较高的准确度。

- ◆ 全连接神经网络只在不同层之间存在连接，当前时刻输出只与当前时刻输入相关，无法解决时序性问题
- ◆ 循环神经网络RNN在相同层的神经元之间添加连接，当前时刻输入不仅与当前时刻输入相关，还与过去时刻相关，能够解决时序性问题

智能信息网络

114

5.2.4 深度学习-神经网络

RNN如何处理时序性问题

$$h_t = \sigma(z^{(t)}) = \tanh[U \cdot x_t + W \cdot h_{t-1} + b]$$

- ◆ RNN当前时刻输出 h_t 由当前时刻输入 x_t 和上一时刻信息 h_{t-1} 经过 $\tanh$ 激活函数后共同决定，这种方式以迭代的形式保存了输入数据的时序性，能够解决短期时序性问题，但难以处理长期记忆问题

<https://www.cnblogs.com/pinard/p/6509630.html> (后同)

智能信息网络

115

5.2.4 深度学习-神经网络

针对RNN难以处理长期记忆问题，引入长短期记忆 (LSTM) 网络

RNN

LSTM

- ◆ RNN神经网络在前向传播过程中，开始时刻的输入对后面时刻的影响越来越小，记忆能力较弱
- ◆ LSTM神经网络通过引入多种门结构，可完成长期记忆模型的训练（例如4000小时基站流量数据）


智能信息网络

116

5.2.4 深度学习-神经网络

LSTM基本结构

- ◆遗忘门：决定舍弃哪些信息
- ◆输入门：选择记忆哪些信息
- ◆输出门：输出哪些状态特征
- ◆细胞状态：承载过去的全部状态信息



细胞状态

遗忘门

输入门

输出门

x_t

h_t

<https://baijiahao.baidu.com/s?id=1663033783656042230&wfr=spider&for=pc> (后同)


智能信息网络 117

5.2.4 深度学习-神经网络

示例：流量预测

案例教学

- 已知某高校教学楼节点的2102条原始流量数据（采样周期为1h），将其分成2个部分：1908（训练集和验证集）+ 194（测试集）
- 利用前面的1908条原始流量数据进行训练和验证，对该节点后面的194小时流量数据进行预测
- 预测结果与原始的194条测试集进行比较



带宽/Gbps


时间/h

智能信息网络 118

5.2.4 深度学习-神经网络

LSTM预测结果展示

案例教学



蓝线为真实数据
橙线为预测结果

2018/5/23 22:00
原始数据流量: 37.9838
预测数据: 38.6159172058105

- 最大偏差: 54.70
- 最大偏差百分比: 58.35%
- 最小偏差: 0.05
- 最小偏差百分比: 0.10%
- 均方根误差 (RMSE) : 12.88

智能信息网络 119

5.2.4 单元小结

1. 掌握神经网络的基本原理
2. 了解人工神经网络在网络中的应用

人工智能是智网的重要分析方法



智能信息网络 120

5.2.5 强化学习

某些应用问题需要算法在每个时刻做出决策并执行动作。



(1) 对于围棋，每一步需要决定在棋盘的哪个位置放置棋子，以最大可能战胜对手。



(2) 对于机器人，需要时刻感知周围的环境，以驱动手臂运动以抓取目标物体、完成地面清扫等任务。



(3) 对于自动驾驶，需要根据路况来确定当前的行驶策略以保证行驶安全。

根据当前的条件做出决策和动作，以达到某一预期目标

智能信息网络 121


5.2.5 强化学习

强化学习定义

强化学习 (reinforcement learning)，又称为再励学习，是指通过环境状态到行为映射的学习、以使系统行为从环境中获得的累积奖励值最大的一种机器学习方法，描述和解决**智能体** (agent) 在与**环境**的交互过程中通过学习策略以达成回报最大化或实现特定目标的问题。

智能体是强化学习中的**动作实体**，是整个强化学习算法的核心。

强化学习模型



```

graph LR
    Agent[智能体] -- 动作 --> Environment[环境]
    Environment -- 回报 --> Agent
    Environment -- 环境感知 --> Agent
  
```


智能信息网络 122

5.2.5 强化学习

强化学习定义

智能体选择一个动作 a 作用于**环境**，环境接收该动作后发生变化，同时产生一个强化信号（奖或罚）反馈给智能体，智能体再根据强化信号和环境的当前状态 s 再选择下一个动作，选择的的原则是使受到正的奖励值的概率增大。

强化学习模型



```

graph LR
    Agent[智能体] -- 动作 Action --> Environment[环境]
    Environment -- 奖励值 R --> Agent
    Environment -- 状态 S --> Agent
  
```

强化学习用于**决策类**问题，如网络中的路由选择、网络节点部署等问题。


智能信息网络 123

5.2.5 强化学习

强化学习基本要素

除了智能体和环境之外，强化学习系统的四个主要子要素：**策略(policy)**、**奖励函数(reward function)**、**值函数(value function)**和一个可选的**环境模型(model)**。

四个要素之间的关系：



策略 Is my goal
奖励 Is I can get
值 Is my method
环境 Is unknown

智能信息网络 124

5.2.5 强化学习

强化学习场景

观察 动作

AlphaGo

奖励

其他, 奖励 = 0
赢棋, 奖励 = 1
输棋, 奖励 = -1

环境

智能信息网络 125

5.2.5 强化学习

强化学习场景

智能体在时间 t 采取动作 $a(t)$, 并将这个动作送到环境中去, 环境将会从状态 $S(t)$ 转移到下一个状态 $S(t+1)$, 基于上述过程环境还将给予一个奖励反馈 R , 如此往复。强化学习要做的就是使得整个序列所能获得的期望奖励最大。

智能体

动作 $a(t)$

环境

奖励 R

$S(t+1)$ $S(t)$

学习目的:
找到能使长期累积奖励最大化的策略

强化学习问题可以抽象成马尔可夫决策过程 (Markov Decision Process, MDP)

智能信息网络 126

5.2.5 强化学习

马尔科夫过程

随机过程 $\{X_n, n \in T\}$, 参数 $T = \{0, 1, 2, \dots\}$, 状态空间 $I = \{i_0, i_1, i_2, \dots\}$

定义 若随机过程 $\{X_n, n \in T\}$, 对任意 $n \in T$ 和 $i_0, i_1, \dots, i_{n+1} \in I$,
 $P\{X_{n+1}=i_{n+1}|X_0=i_0, X_1=i_1, \dots, X_n=i_n\} = P\{X_{n+1}=i_{n+1}|X_n=i_n\}$,
 则称 $\{X_n, n \in T\}$ 为**马尔可夫链**, 简称**马氏链**。

若 $t_1, t_2, \dots, t_{n-2}$ 表示过去, t_{n-1} 表示现在, t_n 表示将来, 马尔可夫过程表明:
 在已知现在状态的条件下, 将来所处的状态与过去状态无关。

智能信息网络 127

5.2.5 强化学习

马尔科夫决策过程

决策特点: 智能体可以执行动作, 在时刻 t , 智能体选择一个动作执行 a , 之后进入下一个状态 s_{t+1} , 环境给出回报值。智能体从某一初始状态开始, 每个时刻选择一个动作执行, 然后进入下一个状态, 得到一个回报, 如此反复。

智能体

动作 a

状态 s

环境

奖励 r

状态 (S) 、动作 (A) 、转移概率 (P) 以及奖励函数 (R)

问题: 对于状态-动作对 (s, a) , 在状态 s 时执行动作 a , 后续状态按照最优策略执行得到预期回报。如何确定最优策略?

智能信息网络 128

5.2.5 强化学习

强化学习可以分为无模型 (Model-Free RL) 和基于模型 (Model-Based RL)

- ◆ **无模型 (Model-Free RL)** : 计算过程依赖于事先知道状态转移概率和立即回报值
- ◆ **基于模型 (Model-Based RL)** : 按照某种策略随机执行不同的动作, 观察得到的回报, 然后进行改进, 即通过随机试错来学习

不需要等到每个事件终止便可以根据未来奖励的最大期望估计进行更新, 在每个步骤间隔进行值函数更新。

强化学习

Model-Free RL

Model-Based RL

蒙特卡洛算法

时序差分学习

基于动态规划的算法

智能信息网络

129

5.2.5 强化学习

示例: 基于Q表的执行

创建Q表, 用来指导智能体的行动, Q表中对对应动作的数值越大, 智能体采取这个动作的概率就越大。

时序差分学习基本迭代更新公式

$$V(s) \leftarrow V(s) + \alpha(R + \gamma V(s') - V(s))$$

更新项

得出Q表迭代公式

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R(S_{t+1}) + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$$

网络的输入对应环境状态的描述, 网络的输出对应每个动作的Q值。

- ◆ $R(S_t)$ 是智能体在 S_t 动作的奖励(Reward)
- ◆ $\max_a Q(S_t, a)$ 是 S_t 状态下, Q 表数值最大的一个;
- ◆ α 是学习速率; γ 为衰减值
- ◆ $R(S_{t+1}) + \gamma \max_a Q(S_{t+1}, a)$ 是 $Q(S_t, A_t)$ 的目标数值

公式推导详细过程见参考书(雷明)

智能信息网络

130

5.2.5 强化学习

应用思考: 移动前传网络中的DU/CU智能配置?

案例教学

- ◆ DU/CU自动配置是网络智能部署的一种特殊形式, 指将DU/CU功能部署到实际的网络环境中
- ◆ 需综合考虑时延以及网络容量等多种因素的影响

造成多种挑战

AAU

DU

CU

DC

基站

处理

处理池

电交换机

ROADM

通用处理器

城域网数据中心

智能信息网络

131

5.2.5 强化学习

应用思考: 移动前传网络中的DU/CU智能配置?

案例教学

动作 Action

给出一个DU/CU部署和路由选择方案

奖励值 R

光路是否满足网络的资源限制和时延要求

状态 S

网络状态, 包括链路容量, 节点计算资源等

卷积神经网络构成的智能体

移动前传网络环境, 包括节点和光路等

智能信息网络

132

5.2.5 强化学习

应用思考：移动前传网络中的DU/CU智能配置？ 案例教学

深度强化学习

$a_t = \max_{a_t} Q^{pi_t}(S_t, a_t)$

动作

交互阶段

训练阶段

记忆库 (S_t, r_t, a_t, S_{t+1})

移动前传网络环境

下一步状态, 奖励

S_{t+1}, r_t

- ① 将部署业务需求和网络状态 (由拓扑, 带宽及节点计算资源组成) 输入神经网络, 神经网络输出各动作 (节点部署位置及路由策略) 的Q值
- ② 选择Q值最大的动作与环境进行交互, 产生下一步状态和该动作对应奖励。
- ③ 多次循环迭代, 收集到一定的数据后, 进行训练阶段。

• **训练阶段:**

- ✓ 利用大量数据训练神经网络


智能信息网络 133

5.2.5 单元小结

1. 掌握强化学习的基本原理
2. 掌握强化学习的基本方法

强化学习可用于网络业务和状态的自适应变化

智能信息网络 134



第5章 小结

1. 机器学习与深度学习基础知识
2. 监督学习中的贝叶斯、支持向量机和决策树 (应用思考)
3. 深度学习中的神经网络 (应用思考)
4. 强化学习的基本方法 (应用思考)

智能信息网络 136



第5章 思考题

- 5.1 请阐述机器学习的基本术语及其意义
- 5.2 请说明机器学习的基本训练步骤
- 5.3 请说明如何得出正确的版本空间
- 5.4 请阐述机器学习算法分类及其各自特点
- 5.5 请说明贝叶斯网络的基本原理与应用场景
- 5.6 请阐述支持向量机的核心思想与基本原理
- 5.7 请说明当支持向量机遇到线性不可分问题时的处理方法
- 5.8 请阐述决策树的生成过程以及其优缺点
- 5.9 请阐述神经网络的基本结构及其功能
- 5.10 请说明卷积神经网络的核心思想与基本原理
- 5.11 请说明强化学习的概念与适用场景

