



智能信息网络

1

智能信息网络概述

2

高速宽带信息网络技术

(基础篇)

3

信息网络性能分析技术

(基础篇)

4

网络数据的智能处理技术

(基础篇)

5

网络中常用的智能算法

(基础篇)

6

网络智能规划

(应用篇)

7

网络智能部署

(应用篇)

8

网络智能运维

(应用篇)

9

网络智能优化

(应用篇)

10

智能信息网络发展前景

1

智能信息网络概述

2

高速宽带信息网络技术

(基础篇)

3

信息网络性能分析技术

(基础篇)

4

网络数据的智能处理技术

(基础篇)

5

网络中常用的智能算法

(基础篇)

6

网络智能规划

(应用篇)

7

网络智能部署

(应用篇)

8

网络智能运维

(应用篇)

9


网络智能优化

(应用篇)

10

智能信息网络发展前景

2



第9章 主要参考资料

1. 中国移动，网络优化的基本概念及内涵概要，2016.12
2. 唐雄燕等，AI+电信网络——运营商的人工智能之路，2020.11
3. <https://www.cnblogs.com/pinard/p/6509630.html>
4. <https://blog.csdn.net/bl128ve900/article/details/98211689>
5. <https://baijiahao.baidu.com/s?id=1663033783656042230&wfr=spider&for=pc>
6. Shaolei, Zhang, et al. "Demonstration of proactive bandwidth allocation using LSTM in 5G optical fronthaul." 2019 ECOC

智能信息网络

8

第9章 网络智能优化

8

9.1 AI驱动的网络优化

9.2 网络流量智能预测

6

第9章 学习目标与教学思路

- ◆ 明确AI驱动的网络优化基本概念
- ◆ 掌握网络流量智能预测的基本方法与典型应用

◆ 3要点：从案例中理解需求，从案例中学习算法，从案例中展望未来

7

9.1 AI驱动的网络优化

网络优化基本定义

网络优化是对运行中的网络进行参数采集和数据分析，找出影响网络质量的原因，采取改进措施，使网络达到最佳运行状态，保证网络资源获得最佳效益，同时了解网络增长趋势，为网络扩容提供依据，为用户提供更好服务体验。

中国移动，网络优化的基本概念及内涵概要，2016.12（后同）

智能信息网络


8



9.1 AI驱动的网络优化

网络智能优化基本概念

- ◆ 网络智能优化基于人工智能技术，根据网络承载、网络流量、用户行为和其他参数来不断优化网络配置，实现主动式的网络自我校正和优化。
- ◆ 通过人工智能技术为当前复杂的信息网络 and 用户需求提供强大的复杂决策能力，从而驱动网络的**智能化转型**。




唐雄燕, 廖军等, AI+电信网络——运营商的人工智能之路, 2020.11(后同)



9.1 AI驱动的网络优化

网络智能优化基本任务

通过对网络性能进行实时分析，对网优大数据进行训练，基于人工智能算法构建智能优化引擎，主动实时做出决策，同时进行主动式优化和调整，使网络处于最佳工作状态。



9.1 AI驱动的网络优化

网络智能优化价值体现

复杂网络环境增加网优难度

- ◆ 网络复杂化，用户网络行为和性能也比以往更加动态化和难以预测
- ◆ 通信业务多样化，单纯通过网络KPI对网络覆盖、容量等进行优化已无法满足用户需求，通信网络运营与优化焦点逐渐从网络性能转向用户体验
- ◆ 传统的网络管理方法和工具已经无法满足运营商的需求，需考虑在网络优化中引入人工智能技术

AI可以提供的帮助

- ◆ 智能环境感知、网络性能预测、智能优化决策等



9.1 AI驱动的网络优化

网络智能优化典型案例

基于预测的业务迁移

场景描述

- ◆ 网络规模剧增、网络复杂度提高，未来业务带宽增长导致原路由无法满足业务需求
- ◆ 基于AI预测未来业务需求，根据网络状态对现有业务进行迁移重构

技术方案

- ◆ 基于时间序列算法的流量预测
- ◆ 基于神经网络的业务迁移决策



无线网络参数智能配置

场景描述

- ◆ 引入人工智能提高无线网络参数管理和分析水平、优化效率
- ◆ 基于AI建立网络状态与覆盖范围、网络容量的关系模型，进行智能分析，设计优化思路

技术方案

- ◆ 基于聚类算法的小区特征分析
- ◆ 基于深度学习的无线网络覆盖优化



9.1 单元小结

AI驱动的网络优化基本概念

优化是智能信息网络建设的重要内容



13

9.2 网络流量智能预测




智能信息网络

14

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

问题引入:
提高带宽资源利用率



5G transport network

解决方案: 动态带宽调整策略

- 被动式调整策略: 业务到达时逐跳上报调整, 大大增加业务时延
- 主动式调整策略: 使用神经网络预测前传流量 (例如: 长短期记忆(LSTM)网络), 预先调整

关键问题: 如何实现高准确度前传流量预测, 并进行主动式带宽分配?

智能信息网络

15


9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

基本原理

训练数据

回顾: 全连接神经网络



损失函数MSE:
$$L(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2$$

问题:
(1) 参数数量大, 训练困难
(2) 未体现时间维度关联性

智能信息网络

16

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

针对问题 (1)：由于全连接神经网络节点很多，参数数量庞大。通过引入卷积神经网络CNN，可以去掉大量不重要参数，降低神经网络模型的复杂度

卷积神经网络CNN

回顾：卷积神经网络

卷积核/滤波器

卷积过程

池化层

Image

Convolved Feature

https://mp.weixin.qq.com/s/t8ig_bpEcQJmgIqKarefQ (后同)

智能信息网络 17

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

针对问题 (2)：由于全连接神经网络未体现时间维度关联性，引入循环神经网络RNN，可以处理时序性问题

全连接神经网络 → 循环神经网络 (RNN)

1. 收集所需的流量数据。 2. 在不同时间传递神经元状态。 3. 更新网络状态及调整参数。 4. 重复直到获取较高的准确度。

- ◆ 全连接神经网络只在不同层之间存在连接，当前时刻输出只与当前时刻输入相关，无法解决时序性问题
- ◆ 循环神经网络RNN在相同层的神元之间添加连接，当前时刻输入不仅与当前时刻输入相关，还与过去时刻相关，能够解决时序性问题

智能信息网络 18

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

RNN如何处理时序性问题

$$h_t = \sigma(z^{(t)}) = \tanh[U \cdot x_t + W \cdot h_{t-1} + b]$$

◆ RNN当前时刻输出 h_t 由当前时刻输入 x_t 和上一时刻信息 h_{t-1} 经过 $\tanh$ 激活函数后共同决定，这种方式以迭代的形式保存了输入数据的时序性，能够解决短期时序性问题

<https://www.cnblogs.com/pinard/p/6509630.html> (后同)

智能信息网络 19

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

RNN训练流程

问题：网络应用中需要解决长期记忆问题，如何应对？

- ◆ 前向传播：
 - (1) 计算隐藏状态 h_t

$$h_t = \sigma_h(U \cdot x_t + W \cdot h_{t-1} + b)$$
 - (2) 计算预测值 y_t

$$y_t = \sigma_y(V \cdot h_t + c)$$
 - 其中，各时刻连接权重 U, W, V 共享； σ_h, σ_y 为激活函数； b, c 为共享偏置
- ◆ 误差函数： $L_t = \text{Loss}(y_t, \hat{y}_t)$
- ◆ 反向传播：
 - 使用梯度下降法，求误差 L 关于共享参数 U, W, V, b, c 的梯度，沿梯度负方向更新参数
 - 但传统RNN存在梯度消失与梯度爆炸等问题，难以处理长期记忆问题


智能信息网络 20



9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

针对RNN难以处理长期记忆问题，引入长短期记忆 (LSTM)网络



- ◆ RNN神经网络在前向传播过程中，开始时刻的输入对后面时刻的影响越来越小，记忆能力较弱
- ◆ LSTM神经网络通过引入多种门结构，可完成长期记忆模型的训练（例如4000小时基站流量数据）

智能信息网络
21




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM基本结构

- ◆ 遗忘门：决定舍弃哪些信息
- ◆ 输入门：选择记忆哪些信息
- ◆ 输出门：输出哪些状态特征
- ◆ 细胞状态：承载过去的全部状态信息



<https://baijiahao.baidu.com/s?id=1663033783656042230&wfr=spider&for=pc>（后同）

智能信息网络
22




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM前向传播基本流程

- ◆ 遗忘阶段：决定舍弃哪些信息
- 输入上一时刻隐藏状态 h_{t-1} 和当前输入信息 x_t ，经过Sigmoid函数产生一个 $[0,1]$ 的数值 f_t ，与上一时刻细胞状态 C_{t-1} 相乘，表示对上一时刻细胞状态的舍弃程度。



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

注：h是隐藏状态，表示短期记忆；C是细胞状态，表示长期记忆

智能信息网络
23




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM前向传播基本流程

- ◆ 输入阶段：选择记忆哪些信息
- 输入 h_{t-1} 和 x_t ，经过Sigmoid函数产生一个 $[0,1]$ 的数值 i_t ，表示对新信息 $\tilde{C}_t$ 的保留程度；新信息 $\tilde{C}_t$ 由 h_{t-1} 和 x_t 通过tanh激活函数生成。



$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

注：h是隐藏状态，表示短期记忆；C是细胞状态，表示长期记忆

智能信息网络
24

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM前向传播基本流程

◆细胞状态更新：更新过去的全部状态信息

□由遗忘阶段计算出的遗忘系数 f_t 乘上一时刻细胞状态 C_{t-1} ，并与由选择系数 i_t 加权的新信息 $\tilde{C}_t$ 相加，得到更新后的当前时刻细胞状态 C_t 。

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

注：h是隐藏状态，表示短期记忆；C是细胞状态，表示长期记忆

智能信息网络

25

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM前向传播基本流程

◆输出阶段：输出哪些状态特征信息

□输入 h_{t-1} 和 x_t ，经过Sigmoid函数产生一个[0,1]的数值 o_t ，表示对输出细胞状态 C_t 的保留程度；输出细胞状态 C_t 经过tanh函数激活，由 o_t 加权后，得到当前隐藏状态的输出信息 h_t 。

$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

注：h是隐藏状态，表示短期记忆；C是细胞状态，表示长期记忆

智能信息网络

26

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM模型设计

◆单层神经元：指每层神经元的数量，可人为调节，不同神经元数量会有不同的效果

◆模型网络层数：指这个LSTM模型共有几层，可人为调节，不同层数会影响模型精度

◆序列长度：指模型中输入特征的数量，由数据集的特征数决定

注：图中红色框表示单层神经元数量，蓝色框表示模型网络层数，绿色框表示序列长度

智能信息网络

27

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

选用LSTM的原因

◆基站的流量数据具备一定的时序性，可以使用时序模型来进行预测

◆ LSTM作为全连接神经网络的演进算法，具备强大的拟合能力

◆ LSTM相同层的神经元之间存在连接，能够处理时序性问题

◆ LSTM引入门控的方式，能够解决梯度消失、梯度爆炸等问题

智能信息网络

28




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

算法流程图

- ◆ **数据导入**：导入一段时间的流量数据
- ◆ **数据预处理**：将数据根据方差和均值进行标准化
- ◆ **训练/验证/测试**：将数据集分为训练集、验证集和测试集
- ◆ **模型搭建**：搭建LSTM的神经网络层次结构
- ◆ **前向传播**：将历史流量输入神经网络，计算预测结果
- ◆ **误差计算**：使用误差函数计算真实值与预测值的误差
- ◆ **更新权重**：使用梯度下降算法反向传播更新模型权重
- ◆ **模型验证**：训练一段时间后验证模型性能，调优模型超参数
- ◆ **模型测试**：载入已收敛的模型及权重，在测试集中测试性能
- ◆ **过程可视化**：绘制并对比预测结果与真实结果的误差




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

案例介绍

- 已知某高校教学楼节点的2102条原始流量数据（采样周期为1h，2018/2/26 10:00至2018/5/31 23:00），将其分成2个部分：1908（训练集和验证集）+194（测试集）
- 利用前面的1908条原始流量数据（采样自2018/2/26 10:00至2018/5/23 21:00）进行训练和验证，对该节点自2018/5/23 22:00至2018/5/31 23:00共194小时的流量数据进行预测
- 预测结果与原始的194条测试集进行比较



9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

数据分割

- **数据集划分**：1908条已知流量数据用于模型训练和验证，分割为90%训练集+10%验证集；另外随后的194条已知流量数据作为测试集，用于评估预测模型的性能。
- (1) **训练集**：用于模型拟合的数据样本
- (2) **验证集**：模型训练前预留的样本集，用于调整超参数、初步评估模型性能
- (3) **测试集**：用于最终评估模型性能，仅使用一次，不能作为调参依据
- **数据集(训练集/验证集/测试集)的作用**
- (1) 训练集直接参与了模型拟合过程，不能判断模型的泛化能力（防止过拟合）
- (2) 验证集参与了人工调整超参数的过程，不能用于模型性能的最终评判
- (3) 测试集未参与模型整体训练过程，能够评估模型性能的优劣

9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

数据预处理

- **数据预处理**：将时间序列流量数据进行**特征缩放**，提升模型收敛速度，提升精度；

- (1) **数据标准化**：将数值转化为正态分布

$$\hat{x} = \frac{x - \mu}{\sigma} \quad (x: \text{原始样本}, \hat{x}: \text{标准化样本}, \mu: \text{样本均值}, \sigma: \text{样本标准差})$$

- (2) **数据归一化**：将数值转为[0,1]区间

$$\hat{x} = \frac{x - \min}{\max - \min} \quad (x: \text{原始样本}, \hat{x}: \text{归一化样本}, \min: \text{样本最小值}, \max: \text{样本最大值})$$

- 预测结果需要反归一化，还原数据




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

训练集数据

- 训练数据与标签：考虑到流量以一星期为周期，每个训练数据设置为7*24h流量数值（168条），经神经网络加权和处理后，输出1h预测数值与训练数据标签（第169条）进行对比，并不断反馈迭代修正。
- 使用滑动窗口从连续时间序列中分割出大量训练集数据。



训练集数据

智能信息网络
33




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM结构设计

- 输入数据特征：
时间、带宽
- 隐藏层：
3层，每层神经元数量为64
- 输出结果：
下一时刻的前传流量带宽
- 时间间隔：
*7*24，即使用前168个前传流量预测第169个前传流量带宽*



智能信息网络
34



9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM超参数设计

符号	描述
隐藏层神经元数量	64
神经网络层数	3
序列长度	168
训练轮数	50000
批训练样本数	1024
学习率	0.1

以上超参数可多次尝试取最佳

智能信息网络
35



9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

损失函数

由于本案例目的是进行流量预测，因此可采用均方根误差作为损失函数

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n |y_i^* - y_i|^2}$$

- ◆ 式中 n 表示样本数量， y_i, y_i^* 分别表示预测结果和真实结果
- ◆ 模型优化的目标就是希望能够最小化预测结果和真实结果之间的误差

智能信息网络
36




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

训练过程可视化

◆ 由于LSTM模型使用均方根误差作为损失函数衡量模型的好坏，因此训练过程可视化主要就是绘制每次迭代的均方根函数值变化曲线，趋于平稳时表示网络收敛



在50000次迭代训练之后，LSTM的RMSE损失值降低到 5×10^{-4} ，模型收敛

智能信息网络
37




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

模型验证

◆ 模型验证：在训练集学习训练之后得到的模型在验证集中进行验证，观察模型在验证集上是否收敛，根据反馈结果及时调整人工神经网络模型参数。

◆ 主要做法就是重载训练后的模型及参数，前向传播得出验证集的预测结果。将预测结果和真实结果对比分析，如误差较大则需要对神经网络进行调参。



在验证集(10%的原始数据组成)中进行验证，如图所示，预测均方根误差可以达到9.29，预测结果接近真实值。

智能信息网络
38




9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM预测结果展示

蓝线为真实数据
橙线为预测结果



2018/5/25 22:00
原始数据流量: 37.9838
预测数据: 38.6159172058105

- 最大偏差: 54.70
- 最大偏差百分比: 58.35%
- 最小偏差: 0.05
- 最小偏差百分比: 0.10%
- 均方根误差 (RMSE) : 12.88

智能信息网络
39



9.2 网络流量智能预测

问题驱动
算法支撑
案例教学

LSTM 小结

◆ 移动前传流量预测指根据以往的历史数据预测未来前传网络流量情况，属于时间序列预测问题

◆ 长短期记忆网络 (LSTM) 通过添加多个门控机制的方式，有效解决长时间序列预测问题，适用于前传流量预测

◆ 长短期记忆网络 (LSTM) 在本案例中展现出非常好的预测效果

◆ 拓展：调整LSTM结构以及修改模型参数会得到不同的预测性能

◆ 拓展：尝试不同的数据预处理方法也会使模型得到不同的预测性能

智能信息网络
40

9.2 单元小结

基于LSTM的网络流量预测基本原理与应用方法



流量预测是网络优化的重要内容



41

第9章 小结

1. 流量预测需求与任务
2. 流量预测分析与算法
3. 基于LSTM的移动前传网络流量智能预测



智能信息网络

42

第9章 思考题

- 9.1 AI驱动的网络运优化，有什么特点？
- 9.2 举例说明网络智能优化具有什么优势？
- 9.3 如何理解基于LSTM的网络流量预测的目标与技术实现方法？



43

智能 + 网络 = ?

你说 我说 大家说

THANKS

