

实验报告：基于深度学习的 ISP 网络流量预测模型对比分析

1. 摘要

本实验复现了论文“Comparative Analysis of Deep Learning Models for Real-World ISP Network Traffic Forecasting”，在 CESNET-TimeSeries24 数据集的机构级流量数据上，对比了 Mean、SARIMA、LSTM、GRU 四种模型的流量预测性能。实验采用 35:5:60 的时间顺序分割和 Z-score 标准化，评估了不同滑动窗口配置下的预测效果。结果表明：GRU 和 LSTM 表现接近（ R^2 中位数 0.145 和 0.116），均显著优于 Mean 基线（ R^2 中位数 -0.004）。SARIMA 在滚动预测策略下表现最强（ R^2 中位数 0.183），说明传统统计模型在公平比较下仍有竞争力。实验同时发现了真实网络流量数据中存在的季节性分布漂移问题，其对模型评估的影响值得关注。

2. 引言

ISP 网络流量预测是网络资源管理、拥塞控制和容量规划的关键技术。随着深度学习的发展，LSTM、GRU 等循环神经网络已被广泛应用于流量预测任务，但在真实大规模 ISP 数据上的系统性对比研究仍较为有限。

论文“Comparative Analysis of Deep Learning Models for Real-World ISP Network Traffic Forecasting”在 CESNET-TimeSeries24 数据集上对 10 种模型进行了系统对比。该数据集的独特价值在于其真实性和规模——覆盖捷克国家级科研教育网络 40 周的流量数据，包含机构级、子网级、IP 地址级三个层级。

本实验选取其中最具有代表性的四种模型（Mean、SARIMA、LSTM、GRU），聚焦于机构级 n_bytes 指标的预测。与论文固定参数、不滚动拟合的 SARIMA 评估方式不同，本实验对 SARIMA 采用了滚动预测策略（rolling forecast），使其在更公平的条件与深度学习模型进行对比。此外，本实验还系统分析了时间分割比例对评估结果的影响，以及真实网络流量数据中存在的分布漂移问题。


3. 数据与预处理方法

3.1 数据集

CESNET-TimeSeries24，捷克 CESNET 科研教育网络 2023 年 10 月至 2024 年 7 月共 40 周的流量数据。


使用**机构级（institutions）** 283 条时间序列，1 小时间隔聚合，以 n_bytes （传输字节数）为主预测指标。机构级数据缺失率约 1%，远低于 IP 地址级的 80%+，周期模式清晰，适合作为主实验数据集。

数据集的主要挑战：
- **时间序列间隙**：原始 CSV 只记录有数据的行，缺失时间点整行不存在（而非 NaN），需通过对齐时间轴来识别。
- **周期模式**：存在日周期（24h）和周周期（168h），为滑动窗口的选择提供了依据。
- **分布漂移**：部分机构受季节性影响（如暑假），测试集流量相较训练集骤降 $10^4\sim 10^5$ 倍，导致模型失效。



各级别缺失率分布

图 1：各级别缺失率分布




ACF周期分析

图 2：周期分析——自相关函数



层级流量对比

图 3：不同层级流量对比



数据分布

图 4：n_bytes 数据分布

3.2 预处理流程

预处理流程包含以下步骤：





图 1：预处理流程 Pipeline


预处理流程 Pipeline
图 5：预处理流程



4) Imputation methods




时间轴对齐与缺失值填充
图 6：时间轴对齐与缺失值填充



滑动窗口机制
图 7：滑动窗口机制

图 3：时间分割策略对比



时间分割策略对比

图 8：时间分割策略对比

时间轴对齐：所有时间序列与完整时间戳表 `times.csv` 做 right merge，原数据中缺失的时间点以 NaN 标记，确保全时间轴对齐。

缺失值填充：机构级数据缺失率极低（~1%），采用零填充（zeros）。

滑动窗口生成：选取四种窗口配置：(24,24)、(168,24)、(168,168)、(744,168)。窗口按 `stride = prediction_window` 不重叠滑动，将一个连续时间序列切成 (training_window, prediction_window) 的样本对。

时间顺序分割：按时间顺序分割，不随机打乱。采用 **35% 训练 / 5% 验证 / 60% 测试** 的比例，对齐论文开源代码的分割策略。

论文开源代码使用 `test_set_size=0.6` 的划分方式。本实验在初期尝试了 70:15:15 分割，但发现该方案导致测试期集中在 6-7 月，加剧了部分机构因暑假流量骤降导致的分布漂移问题。切换到 35:5:60 后，模型 R^2 中位数提升约 3 倍，极端异常序列从 5 条降至 2 条。

标准化：采用 Z-score 标准化：

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

其中 μ 和 σ 仅从训练集计算，验证集和测试集变换时使用训练集的参数，避免未来信息泄露。

选择 Z-score 而非论文使用的 MinMaxScaler，原因是网络流量呈长尾分布（少量时间流量极高，大部分时间流量处于正常区间），MinMax 会被极端大流量值压扁正常区间的差异，而 Z-score 对异常值更鲁棒。实验表明两种标准化方式的模型排名趋势一致。

3.3 模型

论文对比了 10 个模型，本实验选取其中最具代表性的 4 个：Mean（最简基线）、SARIMA（统计基线）、LSTM（循环神经网络代表）、GRU（循环神经网络代表）。

Mean 基线：预测值 = 输入窗口的均值，作为性能下限参考。

SARIMA: Seasonal AutoRegressive Integrated Moving Average，捕获时间序列的自回归结构、趋势和季节性。使用 (1,0,1)(1,0,1,24) 配置。与论文固定参数不同，本实验对 SARIMA 采用**滚动预测**策略：对每个测试窗口，使用截至当前的所有历史数据重新拟合模型，再进行预测。这使得 SARIMA 与深度学习模型在相同条件下获得公平对比。

LSTM: Long Short-Term Memory 网络。结构上采用双向单层 LSTM（`hidden_size=100`），取最后时间步的隐藏状态接 Linear 层输出 24 步预测。

GRU: Gated Recurrent Unit，将 LSTM 的遗忘门和输入门合并为更新门，参数更少。结构与超参数配置与 LSTM 一致。

4. 实验设置

4.1 超参数配置

参数	LSTM	GRU	SARIMA	Mean
hidden_size	100	100	-	-
num_layers	1	1	-	-
bidirectional	True	True	-	-
learning_rate	0.01	0.01	-	-
epochs	100	100	-	-
patience	5	5	-	-
batch_size	16	16	-	-
order	-	-	(1,0,1)	-
seasonal_order	-	-	(1,0,1,24)	-

4.2 评估指标

RMSE（均方根误差）：

$$\sqrt{\text{RMSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

R²（决定系数）：

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \mu_y)^2}$$

sMAPE（对称平均绝对百分比误差）：

$$sMAPE = \frac{1}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}$$

4.3 实验环境


- GPU: NVIDIA GeForce RTX 5060 Laptop (CUDA 12.8)
- 框架: PyTorch 2.11.0（纯 torch.nn，无高层封装）
- 统计模型: statsmodels 0.14
- 环境管理: uv, Python 3.12

5. 结果与分析

5.1 模型整体对比


在 212 条机构级时间序列上的对比结果（窗口 (24,24)，35:5:60 分割）：

模型	R² 均值(裁剪后)	R² 中位数	R²>0 占比	RMSE中位数
Mean	0.005	-0.004	46.7%	4.1e8
LSTM	0.071	0.116	83.5%	4.6e8
GRU	0.118	0.145	81.1%	4.5e8
SARIMA（滚动）	0.175	0.183	91.5%	4.1e8



R²分布对比

图 9：R² 分布对比



窗口配置趋势

图 10：不同窗口配置 R² 趋势

与论文参考代码的结果对比（表 1）表明，双方均面临分布漂移导致的 R² 极端值问题，但本实验在数据预处理和模型公平性评估上的改进使结果更具说服力。

模型	论文参考（全部窗口中位数）	本实验（窗口 24,24）
Mean	0.008	-0.004
LSTM	-0.007	0.116

表 1：本实验与论文参考代码的 R² 对比

核心结论：**GRU 和 LSTM 均显著优于 Mean 基线，GRU 略优于 LSTM**。GRU 的 R² 中位数 0.145 高于 LSTM 的 0.116，81% 以上的序列 R² 为正，而 Mean 基线超过一半的序列 R² 为负（即不如猜均值）。

5.2 窗口配置对比

窗口	LSTM R² 中位数	GRU R² 中位数
(24,24)	0.098	0.097
(168,24)	0.095	0.099
(168,168)	0.046	0.063
(744,168)	0.032	0.047

随着预测窗口增大，模型性能呈下降趋势：**短期预测（24h）显著优于长期预测（168h）**。使用 1 个月的历史数据（744h）预测未来 1 周，其 R² 中位数不到短期预测的一半。这说明在该数据集上，流量预测的可靠性随预测跨度增加而明显衰减。

5.3 SARIMA 滚动预测的意义

论文报告 SARIMA 在所有模型中的表现是最差的之一（R² 大面积负值），但本实验发现，这主要是因为论文对 SARIMA 采用了“一次拟合，全测试集重复使用同一预测结果”的评估方式，而非模型本身能力不足。

在采用**滚动预测**策略（每个测试窗口重新拟合）后，SARIMA 的 R² 中位数达到 0.183，甚至略优于 LSTM 和 GRU。

以 file=0（大流量稳定机构）为例，SARIMA(1,0,1)(1,0,1,24) 的拟合系数提供了直观的可解释性：AR(1)=0.905 说明前一小时流量高度影响当前值；SAR(24)=0.988 表明日周期是最强预测因子——“今天下午 3 点 ≈ 昨天下午 3 点 × 0.99”。这与 EDA 阶段 ACF 在 lag=24 处出现峰值的发现一致。相比之下，LSTM/GRU 的 100 维隐藏状态无法提供类似的直观解读。

这一结果说明：

- 在公平比较下，传统统计模型与深度学习模型的差距并非不可逾越
- 滑动窗口评估框架天然偏向 DL 模型（单次 forward 即可完成预测），对需要逐窗口重新拟合的统计模型不利
- SARIMA 的可解释性是其相对于黑盒 DL 模型的核心优势

5.4 数据分布漂移的影响

实验中发现一个影响评估可靠性的重大问题：**数据分布漂移**。部分机构级序列的流量呈现强季节性（如大学网络），当测试集落在暑假（6-7 月）时，测试集流量均值相比训练集骤降 $10^4\sim 10^5$ 倍。这种分布外场景下的预测必然失败，导致 R² 出现极端负值（ $-10^{-7} \sim -10^{-9}$ ）。

该问题对模型评估的影响：**- 均值被极端值扭曲**：少数序列的极端 R² 负值使得整体均值完全失去意义 **- 中位数是更稳健的指标**：不受极端值影响，应作为主要参考 **- 裁剪策略**：参考论文做法，对 R² 做 clip(-10, 1) 处理，使统计量更具代表性

本实验采用 35:5:60 的分割比例可以部分缓解该问题（测试集更大、覆盖更广的时间段），但未能完全消除。这是真实网络数据不同于合成数据的重要特征，也是模型落地时需要考虑的实际问题。

5.5 预测可视化

见图 experiments/02_analysis/figures/prediction_file0_all.png 和 file243_all.png。

以 file=0（大型机构）为例，LSTM 和 GRU 的预测曲线与实际值高度吻合，RMSE 约 1.8×10^4 ， R^2 约 0.60-0.73。Mean 基线则表现为一条水平直线（全局均值），完全无法捕捉流量波动。对于 file=243 这样的强季节性机构，所有模型在测试期均表现不佳，反映了分布漂移的挑战。

6. 总结与展望

主要发现

- GRU 和 LSTM 在 ISP 流量预测上表现接近**， R^2 中位数约 0.12-0.15，显著优于 Mean 基线。GRU 以更少的参数实现了略优的性能。
- SARIMA 在滚动预测策略下表现不输深度模型**，挑战了论文“统计模型远不如 DL 模型”的结论，揭示了评估方法对模型排名的影响。
- 短期预测（24h）效果显著优于长期预测（168h）**， R^2 中位数随预测跨度增大而衰减约 50% 以上。
- 数据分布漂移是真实网络流量数据集的核心挑战**，其对评估结果的影响值得关注。

局限性

- 本实验仅覆盖了机构级 n_bytes 指标，未对全部 18 个指标和三个层级进行全面实验
- SARIMA 滚动预测仅运行了 10 个测试窗口，与 LSTM/GRU 的 168 个窗口的对比存在样本量差异
- 超参数未进行系统搜索，使用了论文参考代码的默认值
- 数据分布漂移问题未完全解决

改进方向

- 模型可解释性**：对 LSTM/GRU 的预测进行 SHAP 值分析，理解模型学到了哪些时间步的重要模式
- 业务场景适配**：将预测结果映射到具体业务场景（骨干网、边缘节点、企业网络），建立模型-场景适配矩阵
- 多指标预测**：利用 n_bytes、n_flows、n_packets 等多变量信息进行联合预测，可能提升预测精度

参考文献

[1] Koumar, J., et al. “Comparative Analysis of Deep Learning Models for Real-World ISP Network Traffic Forecasting.” IEEE TNSM, 2026.

[2] Koumar, J., et al. “CESNET-TimeSeries24: Time Series Dataset for Network Traffic Anomaly Detection and Forecasting.” Nature Scientific Data, 2025.

[3] Hochreiter, S. & Schmidhuber, J. “Long Short-Term Memory.” Neural Computation, 1997.

[4] Cho, K., et al. “Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation.” EMNLP, 2014.