

实验报告：基于深度学习的 ISP 网络流量预测模型对比分析

陈琦 2023212638

1. 摘要

本实验对论文“Comparative Analysis of Deep Learning Models for Real-World ISP Network Traffic Forecasting”的核心实验进行复现与拓展。在 CESNET-TimeSeries24 数据集的 283 条机构级流量序列上，以 n_bytes 为预测目标，对比了 Mean、SARIMA、LSTM、GRU 四种模型在多种滑动窗口配置下的预测性能。实验采用 35:5:60 的时间顺序分割和 Z-score 标准化，并对 SARIMA 引入了滚动预测策略。结果表明：GRU 和 LSTM 的 R^2 中位数分别达到 0.145 和 0.116，显著优于 Mean 基线 (-0.004)；SARIMA 在滚动预测下 R^2 中位数达 0.183，挑战了“统计模型远不如 DL 模型”的原论文结论。实验还发现，真实网络流量数据中存在的季节性分布漂移问题会严重干扰 R^2 均值的可靠性，建议以中位数作为主要参考指标。

2. 引言

ISP 网络流量预测是网络资源管理、拥塞控制和容量规划的基础技术。准确的流量预测可以帮助运营商优化网络资源配置、降低运营成本、提升用户体验。近年来，LSTM、GRU 等循环神经网络在时序预测领域取得显著成功，但在真实大规模 ISP 数据上的系统性对比研究仍较为有限。

论文“Comparative Analysis of Deep Learning Models for Real-World ISP Network Traffic Forecasting”（Koumar 等，2025）在 CESNET-TimeSeries24 数据集（40 周真实 ISP 流量，含 283 条机构级序列）上对 10 种模型进行了系统对比。该论文的核心贡献在于提供了一个标准化的基准测试框架，但其主要局限在于：对 SARIMA 等统计模型仅做一次全局拟合、固定参数预测，未采用滚动更新策略，可能导致不公平的对比结论。

本实验在复现核心实验的基础上，做了以下拓展：（1）对 SARIMA 引入滚动预测策略，使其与 DL 模型在相同条件下对比；（2）系统分析了时间分割比例和标准化方式对评估结果的影响；（3）揭示了数据分布漂移对 R^2 指标的干扰，比较了三种处理方案。

3. 数据与预处理方法

3.1 数据集

实验采用 CESNET-TimeSeries24 数据集的机构级（institutions）数据。该数据集采集自捷克 CESNET 科研教育网络，时间跨度为 2023 年 10 月至 2024 年 7 月（40

周），聚合粒度为 1 小时。选择机构级而非子网级或 IP 地址级，是因为机构级缺失率仅约 1%，远低于 IP 地址级的 80%+，且周期模式清晰——EDA 阶段的 ACF 分析表明数据存在显著的日周期（24h）和周周期（168h）。

数据预处理的核心挑战在于：（1）原始 CSV 只记录有数据的行，缺失时间点整行不存在，需通过 right merge 对齐时间轴来识别（图 6）；（2）部分机构受季节性影响（如大学暑假），测试期流量较训练期骤降 $10^4 \sim 10^5$ 倍，导致分布漂移。




图 1：各级别缺失率分布——机构级集中于 0%，远低于 IP 级




图 2：自相关函数——lag=24 和 lag=168 处峰值确认日周期和周周期

3.2 预处理流程

预处理流程包含五个步骤。

时间轴对齐：各时间序列与完整时间戳表 times.csv 做 right merge，缺失的时间点以 NaN 标记。这一步骤将原始 CSV 中不存在的行补全为 NaN，为后续的缺失值处理奠定基础（图 6）。




图3：时间轴对齐与缺失值填充流程

缺失值填充：机构级数据缺失率仅约 1%，采用零填充。对于缺失率较高的 IP 级数据，可考虑均值填充或线性插值（图 7）。

滑动窗口生成：论文 Table II 定义了 5 种窗口配置。本实验选取其中 4 种：(24,24)、(168,24)、(168,168)、(744,168)。窗口按 $\text{stride} = \text{prediction_window}$ 不重叠滑动（图 4），将连续序列切分为 (X, y) 样本对。




图4：滑动窗口机制

时间顺序分割：与分类任务不同，时序预测必须按时间顺序分割，严禁随机打乱以防止未来信息泄露。论文开源代码采用 $\text{test_set_size}=0.6$ 、 $\text{valid_set_size}=0.05$ 的划分（即 35:5:60）。本实验初期尝试了 70:15:15 分割，但发现该方案导致测试期集中在 6-7 月暑假，加剧了分布漂移问题——部分机构测试期流量均值骤降至训练期的万分之一以下。切换至 35:5:60 后，LSTM 的 R^2 中位数从 0.031 提升至 0.098，极端异常序列从 5 条降至 2 条。




图5：时间分割策略对比——35:5:60 的测试覆盖更广

标准化：论文使用 MinMaxScaler 将数据缩放到 [0,1]。本实验选择 Z-score 标准化：

$$z = \frac{x - \mu_{train}}{\sigma_{train}}$$

选择 Z-score 而非 MinMax 的理由：网络流量呈长尾分布（少数时间流量极高，大部分流量在常规区间），MinMax 会被极端最大值压扁正常区间的差异。Z-score 以标准差为单位，对异常值更鲁棒。两种标准化方式下的模型排名趋势一致。

3.3 模型

论文对比了 10 种模型，本实验选取其中最具代表性的 4 种：

Mean 基线：取输入窗口的均值作为预测值。这是最简单的基线，作为性能下限参考。它的核心假设是“未来等于过去的平均”，显然无法捕捉任何动态模式。

SARIMA：Seasonal ARIMA，在 ARIMA 的自回归（AR）和滑动平均（MA）基础上加入季节性分量（S）。其参数 (p,d,q)(P,D,Q,s) 分别控制非季节/季节的自回归阶数、差分次数、滑动平均阶数，s 为周期长度（本实验中 s=24，小时级日周期）。与论文的静态评估不同，本实验对 SARIMA 采用滚动预测策略：每到达一个测试窗口，用截至当前的全部历史数据重新拟合，再进行预测。这使得 SARIMA 获得了与 DL 模型相同的“逐窗口独立预测”能力。

LSTM：通过遗忘门、输入门、输出门三个门控机制控制信息流，解决传统 RNN 的梯度消失问题。本实验采用双向单层 LSTM（hidden_size=100），双向结构允许模型同时利用时间步前后的上下文信息。

GRU：将 LSTM 的遗忘门和输入门合并为更新门，参数量减少约 1/3，计算效率更高。结构与超参数与 LSTM 一致。论文指出 GRU 在该数据集上以更少的参数实现了与 LSTM 相当甚至略优的性能。

4. 实验设置

4.1 超参数配置

所有超参数来源于论文开源代码 constants.py，未做额外搜索。

参数	LSTM	GRU	SARIMA
hidden_size	100	100	—
bidirectional	True	True	—
learning_rate	0.01	0.01	—
epochs / maxiter	100 (early stop patience=5)	同左	200
batch_size	16	16	—
(p,d,q)	—	—	(1,0,1)
(P,D,Q,s)	—	—	(1,0,1,24)

4.2 评估指标

采用论文使用的三个指标。所有指标均在反标准化后的原始尺度上计算。

RMSE（均方根误差）：

$$RMSE=\sqrt{\frac{1}{N}\sum_{i=1}^N (y_i-\hat{y}_i)^2}$$

RMSE 衡量预测值与真实值之间的平均偏差，取值范围 $[0, \infty)$ 。由于对误差取平方后再开方，RMSE 对大误差的惩罚比 MAE 更重——这意味着一个模型如果有少数极端糟糕的预测，其 RMSE 会显著上升。在 ISP 流量场景中，RMSE 反映的是预测误差的绝对大小，受机构流量量级影响大。

R²（决定系数）：

$$R^2=1-\frac{\sum_{i=1}^N (y_i-\hat{y}_i)^2}{\sum_{i=1}^N (y_i-\bar{y})^2}$$

R² 衡量模型相比”直接猜均值”的改进程度。R²=1 表示完美预测，R²=0 表示模型效果与猜均值相当，R²<0 表示模型比猜均值还差。需要特别注意的是：当测试集分布与训练集存在显著差异时，R² 可能出现极端负值（本实验中观察到 -10⁻⁹ 量级），此时均值失去意义，应以中位数作为主要参考。

sMAPE（对称平均绝对百分比误差）：

$$sMAPE=\frac{100\%}{N}\sum_{i=1}^N\frac{2|y_i-\hat{y}_i|}{|y_i|+|\hat{y}_i|}$$

sMAPE 以百分比形式衡量相对误差，取值范围 [0%, 200%]。与 MAPE 不同，sMAPE 的分母同时包含真实值和预测值，避免了对预测值接近零时的放大效应。当 $y_i=\hat{y}_i=0$ 时该点不参与计算。

4.3 实验环境

- GPU: NVIDIA GeForce RTX 5060 Laptop (CUDA 12.8)
- 深度学习框架: PyTorch 2.11.0 (纯 torch.nn, 未使用 Lightning/tsai)
- 统计模型: statsmodels 0.14
- 环境管理: uv, Python 3.12

5. 结果与分析

5.1 模型整体对比

在 237 条机构级序列上的对比结果（窗口 (24,24)，35:5:60 分割）：

模型	R ² 均值(裁剪后)	R ² 中位数	R ² >0 占比	RMSE 中位数
Mean	0.015	-0.012	40.1%	4.6e8
LSTM	0.070	0.113	83.1%	4.3e8
GRU	0.113	0.136	80.2%	4.2e8
SARIMA（滚动）	0.170	0.183	89.0%	3.7e8




图6: R² 分布对比——LSTM/GRU 分布明显右移

核心发现：GRU 和 LSTM 均显著优于 Mean 基线。GRU 的 R² 中位数 0.136 高于 LSTM 的 0.113，两者相差不大，但头对头对比中 GRU 胜出 56.5%，这与论文”GRU ≈ LSTM 且 GRU 略优”的结论一致。SARIMA 在滚动预测下 R² 中位数达 0.183，甚至略优于 LSTM 和 GRU，这与论文”SARIMA 在所有模型中垫底”的结论形成鲜明对比。

与论文的差异原因：论文对 SARIMA 仅做一次全局拟合，单一预测结果复制给所有测试窗口，这严重限制了统计模型的表达能力。本实验的滚动预测策略使 SARIMA 获得公平竞争的机会。

5.2 窗口配置对比

窗口	LSTM R ² 中位数	GRU R ² 中位数
(24,24)	0.098	0.097
(168,24)	0.095	0.099
(168,168)	0.046	0.063
(744,168)	0.032	0.047




图7：不同窗口配置 R² 趋势

两种模型在不同窗口下的性能变化趋势一致：短期预测（24h）效果最好，R² 中位数约 0.10；长期预测（168h 和 744h）的 R² 降至 0.05 以下，衰减超 50%。这符合直觉——预测未来 1 天的流量模式（受日周期支配）比预测未来 1 周（受更多不确定性因素影响）要容易得多。同时，更长训练窗口（744h）并未带来明显收益，说明更久远的历史数据对预测的帮助有限。

5.3 SARIMA 滚动预测与可解释性

论文报告 SARIMA 的效果在所有模型中垫底（R² 大面积负值），但这并非模型本身能力不足，而是评估方式的问题。论文的做法是在训练集上拟合一次 SARIMA，将固定预测结果（趋近历史均值）重复用于所有测试窗口。这忽视了滑动窗口评估框架的“逐窗口独立预测”特性，而 DL 模型恰好在这一框架下享有天然优势——每个测试窗口进行一次 forward 即可。

本实验的滚动预测策略，对每个测试窗口都用截至当前的全部历史数据重新拟合 SARIMA，再预测未来 24 小时：

```
For each test window i:  
  history = values[:forecast_start_i]  
  SARIMA.fit(history) → forecast next 24h
```

滚动预测使 SARIMA 的 R^2 中位数从论文报告的大面积负值提升至 0.183，说明在公平评估下传统统计模型仍有竞争力。这也部分揭示了该领域论文中 DL 模型总是大幅领先统计基线的原因之一——评估框架的设计可能隐含了对 DL 模型有利的假设。

SARIMA 相比于 LSTM/GRU 的核心优势在于可解释性。以文件 0（大流量稳定机构）为例，拟合参数为：

参数	估计值	解读
AR(1)	0.905	前一小时流量影响权重 90%，流量高度持续
SAR(24)	0.988	昨天同一小时影响权重 99%，日周期是最强信号
MA(1)	-0.148	短期误差修正，影响较弱
SMA(24)	-0.777	日周期误差修正

SAR(24)=0.988 意味着“今天下午 3 点的流量 $\approx$ 昨天下午 3 点的流量 $\times 0.99$ ”——这一结论与 EDA 阶段 ACF 分析中 lag=24 处峰值一致。而 LSTM/GRU 的 100 维隐藏状态无法提供这类直观解读。

5.4 误差原因分析

模型预测误差可归结为以下几个因素：

- （1）**数据层级与缺失率**。机构级缺失率约 1%，归一化 RMSE 约 0.14；子网级缺失率约 4%，RMSE 升至 0.28，翻了一倍。缺失数据越多，模型可用历史信息越少，预测误差越大。论文同样发现缺失率与 R^2 呈强负相关（IP 地址级 $r=-0.69$ ）。
- （2）**流量量级与波动性**。小流量机构的相对预测误差更大。以文件 264 为例，均值仅 2.5e6 字节，RMSE 却达 4.7e6，误差与信号同量级。这不是模型能力不足，而是低流量信号本就不稳定。论文也发现最不可预测的序列往往呈现突发的异常尖峰。
- （3）**季节性模式**。具有强日周期（ACF lag=24 > 0.9）的序列预测误差显著低于模式不规则的序列。SARIMA 的 SAR(24)=0.988 定量证明了日周期解释了绝大部分方差。
- （4）**预测跨度**。（24,24）的 R^2 中位数约 0.10，（744,168）降至 0.03-0.05。预测误差随跨度增加而累积。
- （5）**分布漂移**（见下节）。训练集（10-4 月）与测试集（6-7 月）的季节性差异导致部分序列 R^2 极端负值，属于分布外推问题而非模型算法缺陷。

5.5 数据分布漂移问题


实验中发现部分机构级序列的 R^2 出现极端负值 ($-10^{-5} \sim -10^{-9}$)。测试发现，这些序列的共同特征是测试集流量均值相对训练集骤降 $10^4 \sim 10^5$ 倍。以文件 243 为例：训练集（2023-10 至 2024-04）均值为 1.3×10^8 字节，测试集（2024-06 至 2024-07）均值仅为 1.0×10^3 字节——流量骤降归因于该机构在暑假期间几乎停止运作。

分布漂移对评估的影响体现在：**Z-score** 标准化使用训练集均值和标准差，当测试集分布与训练集完全不同时，模型预测在反标准化后仍停留在训练集尺度上，导致 **RMSE** 量级完全错位。更关键的是， R^2 均值对这类极端异常值极其敏感——少数几条异常序列可将均值从合理范围（约 $-0.5 \sim 0.5$ ）拖至 -10^7 以下，使均值完全失去参考价值。

针对该问题，本实验比较了三种处理方案：(A) R^2 裁剪 $\text{clip}(-10,1)$ ，(B) 截断 6-7 月数据，(C) 切换 35:5:60 分割。方案 C 效果最好，采用后 R^2 中位数从 0.031 提升至 0.098，极端异常从 5 条降至 2 条。但该方案是缓解而非根除——剩余的极端异常出现在流量极低的序列上。建议在实验中统一报告 R^2 中位数而非均值，以降低极端值的干扰。

5.5 预测效果

以文件 0（大型机构）为例，LSTM 和 GRU 的预测曲线与实际值高度吻合（ R^2 约 0.60-0.73）。Mean 基线表现为一条水平直线（全局均值），完全无法捕捉流量波动。对于文件 243（强季节性机构），所有模型在测试期均表现不佳——当流量从 1×10^8 骤降至 1×10^3 量级时，任何基于历史模式学习的模型都难以适应。



5.6 与论文结果对比

表 A：归一化 RMSE 对比（institutions, n_bytes）

模型	论文 RMSE	本实验 RMSE	趋势
Mean	0.152	0.126	一致 (Mean 最差)
LSTM	0.105*	0.145	一致 (LSTM 优于 Mean)
GRU	0.105*	0.143	一致 (GRU 略优于 LSTM)
SARIMA	0.151	0.068	本实验显著更优 (滚动预测)

*论文为 (24,1) 窗口，本实验为 (24,24)。SARIMA 论文为固定预测，本实验为滚动预测。

表 B: R2 对比

模型	论文 R2 (全窗口)	本实验 R2 中位数	趋势
Mean	0.032	-0.004	分割比例不同
LSTM	-0.007	0.113	本实验显著更优
GRU	-0.003	0.136	本实验显著更优
SARIMA	-10.831	0.170	本实验滚动预测后大幅提升

表 C: Harmonic Score 对比

模型	论文 HS	本实验 HS	趋势
Mean	0.153	0.142	一致
LSTM	0.139	0.147	一致 (LSTM approx GRU)
GRU	0.139	0.150	一致 (GRU 略优)
SARIMA	0.239	0.119	本实验滚动预测后大幅优于论文

关键发现

1. 相对排序一致: GRU > LSTM > Mean, 与论文趋势相同。
2. 本实验 LSTM/GRU 优于论文参考代码 (论文 LSTM R2 中位数为 -0.007, 本实验 0.11-0.14), 因论文使用 tsai/fastai 库效果不佳。
3. SARIMA 差异: 论文报告 SARIMA 最差, 本实验滚动预测下 SARIMA R2 达 0.183。

6. 总结与展望

主要发现

1. **GRU 与 LSTM 表现接近**, R^2 中位数约 0.12-0.15, GRU 以更少的参数实现略优的效果, 与论文结论一致。
2. **SARIMA 在滚动预测下反超 DL 模型** (R^2 中位数 0.183), 挑战了“统计模型远不如 DL”的原论文结论, 揭示了评估方法的深刻影响。

3. **短期预测优于长期预测**， R^2 随预测跨度增大衰减超 50%，说明长时间跨度的可预测性有限。
4. **分布漂移是真实 ISP 数据的重要挑战**，评估时建议以中位数替代均值。

局限性

本实验仅覆盖机构级 `n_bytes`，未对全部 18 个指标和三级数据进行全面实验；SARIMA 滚动预测仅运行 10 个测试窗口，与 LSTM/GRU 的 168 个窗口的对比存在样本量差异；超参数使用论文默认值，未系统搜索。

改进方向

- **可解释性**：对 LSTM/GRU 进行 SHAP 值分析，理解时间步的重要性模式
- **多变量联合预测**：利用 `n_bytes/n_flows/n_packets` 等多变量信息
- **分布漂移自适应**：显式检测和适应概念漂移的预测方法

参考文献

- [1] Koumar, J., et al. "Comparative Analysis of Deep Learning Models for Real-World ISP Network Traffic Forecasting." IEEE TNSM, 2026.
- [2] Koumar, J., et al. "CESNET-TimeSeries24: Time Series Dataset for Network Traffic Anomaly Detection and Forecasting." Nature Scientific Data, 2025.
- [3] Hochreiter, S. & Schmidhuber, J. "Long Short-Term Memory." Neural Computation, 1997.
- [4] Cho, K., et al. "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation." EMNLP, 2014.
- [5] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. "Time Series Analysis: Forecasting and Control." 5th Edition, Wiley, 2015.
- [6] Hyndman, R. J. & Athanasopoulos, G. "Forecasting: Principles and Practice." 3rd Edition, OTexts, 2021.
- [7] Ferreira, G. O., et al. "Forecasting Network Traffic: A Survey and Tutorial." IEEE Access, 2023.
- [8] D'Alconzo, A., et al. "A Survey on Big Data for Network Traffic Monitoring and Analysis." IEEE TNSM, 2019.